

SELECT

percentile_approx(
active_accounts_z_3m,
0.001
) AS p001,

percentile_approx(
active_accounts_z_3m,
0.005
) AS p005,

percentile_approx(
active_accounts_z_3m,
0.01
) AS p01,

percentile_approx(
active_accounts_z_3m,
0.05
) AS p05,

percentile_approx(
active_accounts_z_3m,
0.50
) AS p50,

percentile_approx(
active_accounts_z_3m,
0.95
) AS p95,

percentile_approx(
active_accounts_z_3m,
0.99
) AS p99,

percentile_approx(
active_accounts_z_3m,
0.995
) AS p995,

percentile_approx(
active_accounts_z_3m,
0.999
) AS p999,

MIN(active_accounts_z_3m) AS min_z,

```
MAX(active_accounts_z_3m) AS max_z  
  
FROM  
  bu_frd.model_behavior_features_z_2022_2025  
  
WHERE model_split = 'TRAIN'  
AND active_accounts_z_3m IS NOT NULL;
```

Algo más que debemos revisar: avg vs weighted utilization

Tenemos dos representaciones muy parecidas:

avg account utilization
weighted portfolio utilization

Antes del modelo debemos medir cuánto se parecen.

En TRAIN:

```
SELECT  
  
  CORR(  
    utilization_change_vs_baseline,  
    weighted_utilization_change_vs_baseline  
  ) AS corr_current_utilization,  
  
  CORR(  
    avg_utilization_z_3m,  
    weighted_utilization_z_3m  
  ) AS corr_z_utilization  
  
FROM  
  bu_frd.model_behavior_features_z_2022_2025  
  
WHERE model_split = 'TRAIN';
```

Este resultado es importante.

Si obtenemos algo extremadamente alto, por ejemplo:

0.97+

sabremos que estamos entregando prácticamente la misma señal dos veces a la regresión.

No significa automáticamente eliminar una, pero sí será algo que debemos considerar antes del modelo, especialmente para interpretación de coeficientes.