

í. Para sacar una **vista del dataset analítico final antes del modelado/scoring**, puedes partir de:

```
bu_frd.model_features_ab_final_2022_2025
```

Aunque el nombre tenga `model_features`, esa tabla es el **dataset final de features**; todavía no contiene predicciones, probabilities, scores, coefficients ni resultados del modelo.

Si lo que quieres es una vista más limpia para revisar o mostrar, yo excluiría columnas operativas como `model_split` y `cohort_role`, y dejaría identificación analítica, outcome y features.

Por ejemplo:

```
final_dataset_view <- sdf_sql(  
  sc,  
  "  
  SELECT  
    party_id,  
    observation_date,  
    observation_year,  
    label_3m,  
  
    /* Behavioral transitions */  
    deterioration_acceleration,  
    adverse_acceleration,  
    max_dpd_jump_recent_3m,  
  
    /* Active accounts */  
    active_accounts_change_vs_baseline,  
    active_accounts_changed_flag,  
  
    /* Balance */  
    balance_change_model,  
    log1p_abs_balance_change_model,  
    balance_change_available_flag,  
    balance_recent_months_available,  
    balance_prior_months_available,  
  
    /* Past due */  
    past_due_change_model,  
    past_due_change_available_flag,  
    past_due_recent_months_available,  
    past_due_prior_months_available,  
  
    /* Delinquency */  
    delinquency_share_change_model,
```

```

delinquency_change_available_flag,
delinquency_recent_months_available,
delinquency_prior_months_available,

/* Utilization */
avg_utilization_change_model,
weighted_utilization_change_model,
utilization_change_available_flag,
utilization_recent_months_available,
utilization_prior_months_available,

/* Z-score challengers */
active_accounts_z_model,
active_accounts_z_available_flag,

avg_utilization_z_model,
avg_utilization_z_available_flag,

weighted_utilization_z_model,
weighted_utilization_z_available_flag

FROM bu_frd.model_features_ab_final_2022_2025
"
)

final_dataset_view %>%
  head(20) %>%
  collect()

```

Eso te mostraría algo conceptualmente así:

party_id	observation_date	label_3m	active_change	balance_change	log_abs_balance	avg_util_change	active_z	...
xxx	2023-05-31	0	0.00	-250	5.53	0.012	0.36	...
xxx	2024-02-29	1	0.67	2,140	7.67	-0.038	1.22	...

Si quieres crear una VIEW permanente

En Hive/Spark:

```

sdf_sql(
  sc,
  "
CREATE OR REPLACE VIEW bu_frd.vw_fraud_alert_analytical_final AS

```

```

SELECT
    party_id,
    observation_date,
    observation_year,
    label_3m,

    deterioration_acceleration,
    adverse_acceleration,
    max_dpd_jump_recent_3m,

    active_accounts_change_vs_baseline,
    active_accounts_changed_flag,

    balance_change_model,
    log1p_abs_balance_change_model,
    balance_change_available_flag,
    balance_recent_months_available,
    balance_prior_months_available,

    past_due_change_model,
    past_due_change_available_flag,
    past_due_recent_months_available,
    past_due_prior_months_available,

    delinquency_share_change_model,
    delinquency_change_available_flag,
    delinquency_recent_months_available,
    delinquency_prior_months_available,

    avg_utilization_change_model,
    weighted_utilization_change_model,
    utilization_change_available_flag,
    utilization_recent_months_available,
    utilization_prior_months_available,

    active_accounts_z_model,
    active_accounts_z_available_flag,
    avg_utilization_z_model,
    avg_utilization_z_available_flag,
    weighted_utilization_z_model,
    weighted_utilization_z_available_flag

FROM bu_frd.model_features_ab_final_2022_2025
"
)

```

Luego puedes verla con:

```
sdf_sql(
  sc,
  "
  SELECT *
  FROM bu_frd.vw_fraud_alert_analytical_final
  LIMIT 20
  "
) %>%
  collect()
```

Para una slide o documento

Si la intención es **mostrar una pequeña muestra del dataset en la presentación**, yo haría otra versión sin **party_id**, para no mostrar identificadores:

```
dataset_example <- sdf_sql(
  sc,
  "
  SELECT
    observation_date,
    label_3m,
    active_accounts_change_vs_baseline,
    active_accounts_changed_flag,
    balance_change_model,
    log1p_abs_balance_change_model,
    balance_change_available_flag,
    past_due_change_model,
    delinquency_share_change_model,
    avg_utilization_change_model,
    weighted_utilization_change_model,
    active_accounts_z_model,
    avg_utilization_z_model,
    weighted_utilization_z_model

  FROM bu_frd.model_features_ab_final_2022_2025

  LIMIT 10
  "
) %>%
  collect()
```

dataset_example

Para presentación, esta última es la que recomendaría: **8–10 filas y 8–12 columnas representativas**, no las 30+ columnas completas. Así puedes explicar visualmente que la unidad final es:

$\boxed{\text{1 row = 1 party at one observation date}}$

con:

Outcome + Behavioral Features + Availability Indicators

y todavía **sin ningún model score**.

y la otra consulta si quiero ver una par de caso positivos como los puedo ver en el dataset ?

Sí. Si quieres inspeccionar **unos pocos casos positivos directamente en el dataset final de features**, basta con filtrar:

```
positive_cases <- sdf_sql(  
  sc,  
  "  
  SELECT *  
  FROM bu_frd.model_features_ab_final_2022_2025  
  WHERE label_3m = 1  
  LIMIT 5  
  "  
) %>%  
  collect()
```

positive_cases

Eso te devuelve cinco observaciones con `label_3m = 1`.

Para revisarlas de una forma más manejable, yo seleccionaría solo las columnas principales:

```
positive_cases_view <- sdf_sql(  
  sc,  
  "  
  SELECT  
    party_id,  
    observation_date,  
    observation_year,  
    label_3m,  
  
    deterioration_acceleration,  
    adverse_acceleration,  
    max_dpd_jump_recent_3m,  
  
    active_accounts_change_vs_baseline,  
    active_accounts_changed_flag,  
  
    balance_change_model,  
    log1p_abs_balance_change_model,  
    balance_change_available_flag,
```

```

    past_due_change_model,
    past_due_change_available_flag,

    delinquency_share_change_model,
    delinquency_change_available_flag,

    avg_utilization_change_model,
    weighted_utilization_change_model,
    utilization_change_available_flag,

    active_accounts_z_model,
    active_accounts_z_available_flag,
    avg_utilization_z_model,
    avg_utilization_z_available_flag,
    weighted_utilization_z_model,
    weighted_utilization_z_available_flag

FROM bu_frd.model_features_ab_final_2022_2025

WHERE label_3m = 1

LIMIT 5
"
) %>%
  collect()

positive_cases_view

```

Si quieres ver casos positivos “reales” junto con la fecha del alert

Esta versión es más útil para QA porque puedes comprobar visualmente que el evento realmente sucede **después de `observation_date` y dentro de los 3 meses**.

Asumiendo que `bu_frd.party_first_valid_alert_all` contiene la fecha del primer qualifying alert:

```

positive_cases_with_alert <- sdf_sql(
  sc,
  "
SELECT
  f.party_id,
  f.observation_date,
  f.label_3m,

  a.first_valid_alert_date,

  months_between(

```

```

        a.first_valid_alert_date,
        f.observation_date
    ) AS months_to_alert,

    f.active_accounts_change_vs_baseline,
    f.active_accounts_changed_flag,

    f.balance_change_model,
    f.log1p_abs_balance_change_model,
    f.balance_change_available_flag,

    f.avg_utilization_change_model,
    f.weighted_utilization_change_model,
    f.utilization_change_available_flag,

    f.active_accounts_z_model,
    f.avg_utilization_z_model,
    f.weighted_utilization_z_model

FROM bu_frd.model_features_ab_final_2022_2025 f

LEFT JOIN bu_frd.party_first_valid_alert_all a
    ON f.party_id = a.party_id

WHERE f.label_3m = 1

LIMIT 5
"
) %>%
collect()

```

positive_cases_with_alert

Solo revisaría antes el nombre exacto de la columna de fecha en `party_first_valid_alert_all`; si no se llama `first_valid_alert_date`, cámbiala por el nombre real.

Para un caso positivo deberías observar conceptualmente:

$$ObservationDate < AlertDate \leq ObservationDate + 3 \text{ months}$$

Por ejemplo:

```

party      XXXXX
observation_date  2024-01-31
label_3m      1
alert_date    2024-03-15

```

```
active change    +0.67
balance change   -2,450
log abs balance   7.80
util change      -0.03
...
```

Esto es muy útil porque convierte una fila abstracta del dataset en una **case study**.

Incluso mejor: ver todo el historial de 12 meses de uno de esos positives

Después de identificar un **party_id**, puedes inspeccionar cómo evolucionó mes a mes:

```
positive_party_history <- sdf_sql(
  sc,
  "
  SELECT
    party_id,
    observation_date,
    feature_month,
    month_offset,
    feature_window,

    reported_accounts,
    active_accounts,
    avg_balance_active,
    avg_past_due_active,
    delinquent_account_share,
    avg_utilization,

    deterioration_count,
    adverse_entry_count,
    max_dpd_jump

  FROM bu_frd.model_party_behavior_monthly_2022_2025

  WHERE party_id = 'AQUI_EL_PARTY_ID'

  ORDER BY month_offset DESC
  "
) %>%
  collect()

positive_party_history
```

Esta última es probablemente la más interesante si quieres explicar un caso individual, porque puedes mostrar:

$$M - 11 \rightarrow M - 10 \rightarrow \dots \rightarrow M0$$

y después:

futurealertwithin3months

Así puedes comprobar visualmente cómo las **12 observaciones mensuales se convierten en una sola fila de engineered features**.