

La disponibilidad de controles es excelente: incluso el estrato más restrictivo tiene aproximadamente **398 controles disponibles por caso**, muy por encima de los 20 que queremos seleccionar. Así que el matching por `data_date + active_accounts_band` es totalmente viable.

Además, los 149 casos están repartidos durante todo 2025. Enero tiene 31 casos, aproximadamente 21% del total, así que está algo más concentrado, pero no parece suficiente para invalidar el diseño; precisamente por eso estamos haciendo matching por mes.

1. No hagamos **SELECT *** en el case-control

El error:

Cases = 61 columnas

Controls = 62 columnas

ocurre porque `alert_controls_matched_3m_2025` tiene alguna columna auxiliar creada durante el matching, como `control_rank` y/o `case_count`.

En vez de intentar igualar las 60+ columnas, recomiendo algo mejor: crear ya un **dataset analítico compacto** con únicamente las variables que necesitamos para este primer EDA.

Así además evitamos arrastrar columnas auxiliares y campos que todavía no analizaremos.

```
DROP TABLE IF EXISTS bu_frd.alert_case_control_3m_2025;
```

```
CREATE TABLE bu_frd.alert_case_control_3m_2025
USING PARQUET
AS
```

```
SELECT
  party_id,
  data_date,

  active_accounts,
  active_accounts_band,

  deteriorations_recent_3m,
  deteriorations_prior_9m,
  deterioration_acceleration,

  adverse_recent_3m,
  adverse_prior_9m,
  adverse_acceleration,

  avg_past_due_recent_3m,
```

avg_past_due_prior_9m,
past_due_change_vs_baseline,

avg_balance_recent_3m,
avg_balance_prior_9m,
balance_change_vs_baseline,

avg_pct_delinquent_recent_3m,
avg_pct_delinquent_prior_9m,
delinquency_share_change_vs_baseline,

avg_utilization_recent_3m,
avg_utilization_prior_9m,
utilization_change_vs_baseline,

max_dpd_jump_recent_3m,

first_alert_date,

1 AS case_flag

FROM bu_frd.alert_positive_3m_first_observation_2025_v2

UNION ALL

SELECT

party_id,
data_date,

active_accounts,
active_accounts_band,

deteriorations_recent_3m,
deteriorations_prior_9m,
deterioration_acceleration,

adverse_recent_3m,
adverse_prior_9m,
adverse_acceleration,

avg_past_due_recent_3m,
avg_past_due_prior_9m,
past_due_change_vs_baseline,

avg_balance_recent_3m,
avg_balance_prior_9m,

```
balance_change_vs_baseline,  
  
avg_pct_delinquent_recent_3m,  
avg_pct_delinquent_prior_9m,  
delinquency_share_change_vs_baseline,  
  
avg_utilization_recent_3m,  
avg_utilization_prior_9m,  
utilization_change_vs_baseline,  
  
max_dpd_jump_recent_3m,  
  
first_alert_date,  
  
0 AS case_flag
```

```
FROM bu_frd.alert_controls_matched_3m_2025;
```

Esto es mucho más limpio para el análisis.

2. Valida que tengamos aproximadamente 149 casos y 2,980 controles

```
SELECT  
  case_flag,  
  
  COUNT(*) AS row_count,  
  
  COUNT(DISTINCT party_id) AS party_count  
  
FROM bu_frd.alert_case_control_3m_2025  
  
GROUP BY case_flag  
  
ORDER BY case_flag DESC;
```

Esperaría aproximadamente:

```
case_flag = 1  
149 filas  
149 parties
```

```
case_flag = 0  
~2,980 filas  
~2,980 parties
```

El número de controles puede ser algo menor si algún control fue seleccionado en más de un `data_date`, porque estamos trabajando a nivel `party-month`. Eso no es necesariamente un error para este EDA.

3. Antes de mirar las features, validemos que el matching funcionó

Aunque tenemos suficientes controles, quiero comprobar que los casos y controles quedaron alineados por exposición.

Ejecuta:

```
SELECT
  case_flag,

  ROUND(
    AVG(active_accounts),
    2
  ) AS avg_active_accounts,

  percentile_approx(
    active_accounts,
    0.50
  ) AS median_active_accounts,

  percentile_approx(
    active_accounts,
    0.90
  ) AS p90_active_accounts

FROM bu_frd.alert_case_control_3m_2025

GROUP BY case_flag

ORDER BY case_flag DESC;
```

Y también:

```
SELECT
  case_flag,
  active_accounts_band,

  COUNT(*) AS row_count,
```

```

ROUND(
  100.0 * COUNT(*)
  / SUM(COUNT(*)) OVER (
    PARTITION BY case_flag
  ),
  2
) AS pct_within_group

FROM bu_frd.alert_case_control_3m_2025

GROUP BY
  case_flag,
  active_accounts_band

ORDER BY
  active_accounts_band,
  case_flag DESC;

```

Idealmente las distribuciones deberían ser muy similares.

4. Después hacemos la primera prueba de señal real

Aquí finalmente vamos a responder:

¿Los futuros alert-positive presentan más deterioro financiero aproximadamente tres meses antes de la alerta?

Empezaría con variables binarias porque son muy fáciles de interpretar.

```

SELECT
  case_flag,

  COUNT(*) AS observation_count,

  /* Recent deterioration */

  SUM(
    CASE
      WHEN deteriorations_recent_3m > 0
      THEN 1 ELSE 0
    END
  ) AS obs_with_recent_deterioration,

```

```

ROUND(
  100.0 *
  SUM(
    CASE
      WHEN deteriorations_recent_3m > 0
      THEN 1 ELSE 0
    END
  ) / COUNT(*),
  2
) AS pct_recent_deterioration,

```

/* Deterioration acceleration */

```

SUM(
  CASE
    WHEN deterioration_acceleration > 0
    THEN 1 ELSE 0
  END
) AS obs_with_deterioration_acceleration,

```

```

ROUND(
  100.0 *
  SUM(
    CASE
      WHEN deterioration_acceleration > 0
      THEN 1 ELSE 0
    END
  ) / COUNT(*),
  2
) AS pct_deterioration_acceleration,

```

/* Recent adverse */

```

SUM(
  CASE
    WHEN adverse_recent_3m > 0
    THEN 1 ELSE 0
  END
) AS obs_with_recent_adverse,

```

```

ROUND(
  100.0 *
  SUM(
    CASE
      WHEN adverse_recent_3m > 0
      THEN 1 ELSE 0
    END
  ) / COUNT(*),
  2
) AS pct_recent_adverse,

```

```

        END
      ) / COUNT(*),
      2
    ) AS pct_recent_adverse

```

FROM bu_frd.alert_case_control_3m_2025

GROUP BY case_flag

ORDER BY case_flag DESC;

Este puede convertirse en uno de los primeros resultados realmente importantes del proyecto.

Por ejemplo, si apareciera:

	CONTROL	CASE
Recent deterioration	7%	15%
Acceleration	5%	13%
Recent adverse	2%	6%

estaríamos viendo una señal bastante interesante.

Si sale algo como:

	CONTROL	CASE
Recent deterioration	8%	8%
Acceleration	6%	6%
Recent adverse	2%	2%

entonces sabremos que estas features, aunque describen comportamiento crediticio real, **no distinguen vulnerabilidad hacia la fraud alert**.

Ambos resultados serían útiles.

5. También quiero comparar magnitudes, no solo flags

Como las variables son muy sesgadas, usemos mediana, P75, P90 y P95.

```

SELECT
  case_flag,

  /* Deterioration acceleration */

  percentile_approx(

```

```
    deterioration_acceleration,  
    array(0.50,0.75,0.90,0.95),  
    10000  
  ) AS deterioration_acceleration_pct,
```

```
/* Past due change */
```

```
percentile_approx(  
  past_due_change_vs_baseline,  
  array(0.50,0.75,0.90,0.95),  
  10000  
  ) AS past_due_change_pct,
```

```
/* Delinquency share */
```

```
percentile_approx(  
  delinquency_share_change_vs_baseline,  
  array(0.50,0.75,0.90,0.95),  
  10000  
  ) AS delinquency_share_change_pct,
```

```
/* Balance */
```

```
percentile_approx(  
  balance_change_vs_baseline,  
  array(0.50,0.75,0.90,0.95),  
  10000  
  ) AS balance_change_pct,
```

```
/* Utilization */
```

```
percentile_approx(  
  utilization_change_vs_baseline,  
  array(0.50,0.75,0.90,0.95),  
  10000  
  ) AS utilization_change_pct
```

```
FROM bu_frd.alert_case_control_3m_2025
```

```
GROUP BY case_flag
```

```
ORDER BY case_flag DESC;
```

6. Y agregaría una métrica sencilla de diferencia relativa

Para los eventos binarios podemos calcular algo muy interpretable:

$$\text{Risk Ratio} = \frac{P(\text{feature} | \text{control})}{P(\text{feature} | \text{case})}$$

Por ejemplo:

deterioration acceleration:

Cases = 12%

Controls = 6%

Relative prevalence = 2.0x

Eso significaría:

Aproximadamente tres meses antes de la primera alerta, los casos presentan aceleración del deterioro dos veces más frecuentemente que controles comparables.

No sería todavía causalidad ni performance de modelo, pero sí evidencia de señal.

Podemos calcularlo después de ver los porcentajes.

7. Sobre enero de 2025

Los casos por mes:

Jan 31

Feb 9

Mar 10

Apr 14

...

Nov 18

Dec 13

no son perfectamente uniformes, pero **el matching mensual nos protege bastante bien contra eso.**

Cada uno de los 31 casos de enero se compara con controles de enero, cada caso de febrero con febrero, etc.

Por eso no intentaría balancear artificialmente los casos entre meses.

Estado del proyecto en este punto

Ya hemos avanzado de:

EDA de la fuente



features conductuales



baseline 12m



recent 3m



acceleration



FIRST ALERT LABEL



matched case-control

Estamos literalmente en el punto donde podremos evaluar por primera vez si **trades** tiene **señal precursora de la primera fraud alert**.

Primero genera el dataset compacto corregido y pásame tres resultados: **conteo cases/controls**, **distribución de **active_accounts_band** por **case_flag****, y la **tabla con % **recent deterioration**, % **deterioration acceleration** y % **recent adverse****. Esa última será especialmente importante.