

Correcto. Mi código anterior asumía que ya habías traído la tabla a un `data.frame` de R. Como la información sigue en **Spark/Hive**, primero debemos leer únicamente el sample desde Hive y después, como son ~66K registros, traerlo a R para una revisión rápida.

Si estás trabajando con `sparklyr` y ya tienes una conexión Spark llamada `sc`, lo haría así.

```
library(sparklyr)
library(dplyr)
library(ggplot2)

# Tabla que ya creamos en Spark/Hive
tenure_spark <- tbl(
  sc,
  dbplyr::in_schema(
    "bu_frd",
    "party_alert_tenure_sample_censored"
  )
)

# Revisar columnas disponibles
colnames(tenure_spark)
```

Primero verifica que allí estén las variables que quieres analizar, por ejemplo:

```
party_id
first_alert_date
alert_year
age_at_first_alert
state_at_first_alert
tenure_full_months_at_alert
left_censored_flag
tenure_quality_status
```

Si los nombres de edad o estado son diferentes, solo sustituimos los nombres en el código siguiente.

Traer el sample a R

Como esta tabla tiene aproximadamente 66K personas, sí es razonable hacer `collect()`:

```
df <- tenure_spark %>%
  select(
    party_id,
    first_alert_date,
    alert_year,
    age_at_first_alert,
    state_at_first_alert,
```

```
tenure_full_months_at_alert,  
left_censored_flag,  
tenure_quality_status  
) %>%  
collect()
```

No haría esto con **trades** ni con **person_restricted** completos. Aquí funciona porque estamos trabajando con la tabla pequeña del sample.

Después confirma:

```
dim(df)  
names(df)  
head(df)
```

Deberías obtener aproximadamente:

~66,643 rows

Distribución rápida de edad

```
summary(df$age_at_first_alert)
```

```
table(df$age_at_first_alert)
```

Para verla mejor por bandas:

```
df <- df %>%  
  mutate(  
    age_band = case_when(  
      age_at_first_alert >= 18 & age_at_first_alert <= 24 ~ "18-24",  
      age_at_first_alert <= 34 ~ "25-34",  
      age_at_first_alert <= 44 ~ "35-44",  
      age_at_first_alert <= 54 ~ "45-54",  
      age_at_first_alert <= 64 ~ "55-64",  
      age_at_first_alert <= 74 ~ "65-74",  
      age_at_first_alert >= 75 ~ "75+",  
      TRUE ~ "UNKNOWN"  
    )  
  )
```

Tabla:

```
table(df$age_band)
```

Porcentajes:

```
round(
```

```
prop.table(table(df$age_band)) * 100,
2
)
```

Gráfico rápido:

```
ggplot(df, aes(x = age_band)) +
  geom_bar() +
  labs(
    title = "Age Distribution - Fraud Alert Sample",
    x = "Age Band",
    y = "Party Count"
  ) +
  theme_minimal()
```

Distribución de State

Para conteos:

```
table(df$state_at_first_alert, useNA = "ifany")
```

Para porcentajes:

```
round(
  prop.table(
    table(df$state_at_first_alert, useNA = "ifany")
  ) * 100,
  2
)
```

Si quieres verlo ordenado:

```
state_table <- df %>%
  mutate(
    state_at_first_alert = ifelse(
      is.na(state_at_first_alert),
      "UNKNOWN",
      state_at_first_alert
    )
  ) %>%
  count(state_at_first_alert, sort = TRUE) %>%
  mutate(
    pct = round(100 * n / sum(n), 2)
  )
```

```
state_table
```

Y top 15:

```
ggplot(
  head(state_table, 15),
  aes(
    x = reorder(state_at_first_alert, pct),
    y = pct
  )
) +
  geom_col() +
  coord_flip() +
  labs(
    title = "Top States - Fraud Alert Sample",
    x = "State",
    y = "Percent"
  ) +
  theme_minimal()
```

Distribución de tenure

Aquí sí usamos únicamente el segmento **no censurado y válido**:

```
df_tenure <- df %>%
  filter(
    left_censored_flag == 0,
    tenure_quality_status %in%
      c("VALID", "SAME_DAY_START_AND_ALERT")
  )
```

Confirma el tamaño:

```
nrow(df_tenure)
```

Debería estar aproximadamente en:

37,492

Resumen:

```
summary(df_tenure$tenure_full_months_at_alert)
```

Percentiles:

```
quantile(
  df_tenure$tenure_full_months_at_alert,
  probs = c(.10, .25, .50, .75, .90, .95),
  na.rm = TRUE
)
```

Para verlo en años:

```
df_tenure <- df_tenure %>%  
  mutate(  
    tenure_years =  
      tenure_full_months_at_alert / 12  
  )
```


Y gráfico:

```
ggplot(df_tenure, aes(x = tenure_years)) +  
  geom_histogram(binwidth = 1) +  
  labs(  
    title = "Tenure at First Fraud Alert",  
    subtitle = "Uncensored sample",  
    x = "Tenure (Years)",  
    y = "Party Count"  
  ) +  
  theme_minimal()
```

La estructura correcta sería entonces

Spark / Hive

bu_frd.party_alert_tenure_sample_censored



Esto es apropiado para una **revisión interna rápida**. Si `age_at_first_alert` y `state_at_first_alert` tienen otros nombres en tu tabla, pásame simplemente el `colnames(tenure_spark)` y te adapto el bloque exacto sin cambiar el resto del análisis.