

Slide 1 — Fraud Alert Vulnerability: Engineered Feature Validation

Esta es la portada y sirve para posicionar el objetivo del reporte. Aquí conviene aclarar desde el inicio que este documento **no evalúa todavía el desempeño del modelo**. Estamos evaluando las variables que alimentarán al modelo.

La pregunta central es:

Do the engineered features differentiate future fraud – alert observations?

El outcome sigue siendo la colocación futura de un qualifying fraud alert dentro del horizonte definido. No estamos diciendo que estas personas hayan experimentado fraude confirmado ni estamos modelando default.

Una forma natural de presentarlo sería:

“After confirming data readiness, the next step was to validate whether the engineered behavioral features actually contain meaningful separation. In this report I focus on feature behavior, availability, non-linearity, redundancy and the relative usefulness of the Current and Z-score representations.”

La palabra importante aquí es **feature validation**, no model validation.

Slide 2 — Feature Engineering Framework

Esta slide explica **de dónde salen las variables** y evita que el manager vea nombres como **deterioration_acceleration** o **log1p_abs_balance_change** sin contexto.

Partimos de 12 meses utilizables de historia comportamental:

9monthsPRIOR + 3monthsRECENT

y el principio general es comparar comportamiento reciente contra una referencia histórica.

Para una variable continua sencilla, conceptualmente usamos:

$$\Delta X = \bar{X}_{Recent3} - \bar{X}_{Prior9}$$

Pero no todas las features se construyen exactamente igual. Tenemos diferentes familias.

Account exposure captura cambios en el número de cuentas activas. No solo conservamos el cambio firmado, sino que posteriormente comprobamos que el hecho de que exista un cambio es particularmente importante.

Balance conserva dos interpretaciones distintas. Una es el cambio firmado:

$$BalanceChange$$

y la otra es la magnitud:

$$\log(1 + |BalanceChange|)$$

La transformación logarítmica reduce el impacto de colas extremas pero mantiene el orden de magnitud.

Utilization tiene dos variantes. Average utilization da el mismo peso conceptual a las cuentas elegibles, mientras weighted utilization pondera implícitamente por la exposición mediante balances y límites.

También construimos features basadas en **transiciones de MOP**, como deterioration, adverse entries y max DPD jump.

Finalmente tenemos los **Z-score challengers**. El objetivo del Z no era simplemente medir un cambio absoluto sino preguntar:

¿qué tan inusual es el comportamiento reciente respecto a la historia de esta misma persona?

La fórmula conceptual es:

$$Z = \frac{\bar{X}_{Recent3} - \bar{X}_{Prior9}}{SD_{Prior9}/\sqrt{3}}$$

La idea que debes transmitir aquí es:

“The feature set intentionally captures different concepts: absolute behavioral change, magnitude of change, unusual change relative to personal history, transition events and data observability.”

Esto prepara al público para entender por qué no esperamos que todas las variables tengan la misma forma.

Slide 3 — Feature Separation Is Uneven Across Behavioral Families

Esta slide es una vista de alto nivel de los resultados.

El mensaje principal no es que todas las features funcionen. De hecho, una de las conclusiones importantes es exactamente lo contrario:

la fuerza de la señal es heterogénea.

Algunas familias muestran una separación bastante clara:

- active-account change,
- balance magnitude,
- feature availability.

Otras muestran una separación más moderada y no lineal:

- utilization,
- Z-score utilization.

Y otras tienen poco poder marginal:

- deterioration acceleration,
- adverse acceleration,
- max DPD jump.

Esto es metodológicamente sano. Si todas las features parecieran extremadamente fuertes, sería incluso una razón para investigar leakage.

Lo que estamos viendo es más realista: algunas variables parecen capturar dimensiones relevantes del comportamiento; otras aportan poco de manera individual.

Aquí también conviene explicar la diferencia entre **marginal signal** e **incremental model signal**.

Una variable puede verse débil de forma aislada y aun así aportar cuando se combina con otras. Por eso en esta presentación utilizamos términos como **LOW PRIORITY**, pero no estamos eliminando variables únicamente por esta slide.

Una buena narrativa sería:

“The engineered variables do not contribute equally. The strongest marginal separation comes from structural change, balance-change magnitude and feature availability. Traditional credit deterioration variables are considerably weaker for this particular outcome.”

Slide 4 — Data Availability Is a Major Component of Feature Separation

Esta es una de las slides más importantes de todo el reporte.

Aquí comparamos la positive rate cuando una feature puede calcularse frente a cuando no puede calcularse.

Por ejemplo:

[Balance\ available: 10.93\%]

contra:

[Balance\ unavailable: 1.53\%]

Para utilization:

[11.67\% \quad vs \quad 2.74\%]

Y para los Z de utilization:

[12.31\% \quad vs \quad 3.69\%]

La línea de referencia de aproximadamente:

[9.09\%]

corresponde al balance del analytical sample.

Es fundamental que expliques aquí que **9.09% no es la prevalencia poblacional**. La muestra fue construida aproximadamente 1:10, por lo que esa tasa es consecuencia del sampling design.

El hallazgo importante es otro:

missingness is informative.

La ausencia de una feature no parece ser aleatoria.

Si una persona no tiene suficiente historial elegible para calcular utilization, balance change o un Z-score, eso contiene información sobre su estructura de archivo crediticio.

Por eso durante feature engineering no hicimos simplemente:

NULL $\rightarrow$ 0

y olvidamos el problema.

Utilizamos el patrón:

$\mathbb{I} \text{ FeatureModel} = \begin{cases} \text{Feature}, & \text{available} \\ 0, & \text{unavailable} \end{cases} \mathbb{I}$

acompañado por:

AvailabilityFlag

De esta forma el modelo puede distinguir entre:

“el verdadero valor es aproximadamente cero”

y:

“la feature no pudo calcularse”.

Lo que **no** debemos decir es que tener más información “cause” fraud alert placement.

La interpretación correcta es:

“Feature observability is associated with the outcome and likely reflects underlying credit-file depth and exposure.”

Slide 5 — Active-Account Change Is More Informative Than Its Direction

Esta slide tiene una señal particularmente limpia.

Los resultados son aproximadamente:

$\mathbb{I} \text{ Negative} \backslash \text{change} = 11.42\% \mathbb{I} \mathbb{I} \text{ Positive} \backslash \text{change} = 11.82\% \mathbb{I} \mathbb{I} \text{ Zero} \backslash \text{change} = 4.57\% \mathbb{I}$

Si solo miráramos el signo, podríamos esperar algo como:

Positive > Zero > Negative

o lo contrario.

Pero eso no ocurre.

Positive y negative son muy parecidos.

Lo verdaderamente diferente es:

ChangevsNoChange

Cuando agrupamos ambos lados:

[Changed=11.63\%][NoChange=4.57\%]

La relación es aproximadamente:

$$\frac{11.63}{4.57} \approx 2.54$$

Es decir, la positive concentration es alrededor de **2.5 veces mayor** cuando existe algún cambio en active accounts que cuando no existe cambio.

Eso explica por qué construimos:

`active_accounts_changed_flag`

además de mantener:

`active_accounts_change_vs_baseline.`

Aquí hay una idea importante para un Senior Data Scientist: una feature binaria aparentemente simple puede capturar mejor la estructura de la relación que una sola variable lineal signed.

Puedes explicarlo así:

“The direction of account-count movement is not the main effect. What differentiates the observations is structural instability itself — whether the active-account configuration changed.”

No diría todavía que es “la mejor feature”, porque eso exigiría evidencia de modelo.

Slide 6 — Balance Magnitude Captures a Non-Linear Signal

Esta slide explica una de las decisiones de feature engineering más importantes.

Primero evaluamos el balance change firmado:

$$\Delta Balance = Balance_{Recent} - Balance_{Prior}$$

Pero al revisar su shape observamos una relación aproximadamente U-shaped.

En términos conceptuales:

Large negative movement → higher concentration

Near zero → lower

Large positive movement → higher

Eso es problemático para una regresión logística lineal.

Una feature signed supone que moverse hacia la derecha de la distribución tiene un efecto sistemáticamente distinto que moverse hacia la izquierda.

Pero aquí parece importar también la **magnitud del movimiento**, independientemente de la dirección.

Por eso construimos:

$$\log(1 + |\Delta \text{Balance}|)$$

Y los deciles muestran una relación mucho más limpia:

\[D1=6.94\% \]

subiendo gradualmente hasta aproximadamente:

\[D10=13.00\% \]

No es perfectamente monotonía en cada decil, pero la tendencia general es clara.

La transformación log también tiene otra ventaja: balance presenta una cola extremadamente larga. Aplicar:

$$\log(1 + x)$$

reduce el impacto numérico de movimientos extremos.

Además, la correlación entre signed balance y log-absolute balance es solo:

$$r = 0.054$$

Es prácticamente nula.

Eso nos dice que las dos features representan conceptos distintos:

Signed balance → *direction*

LogAbs balance → *magnitude*

Por eso la conclusión de esta slide es:

Signed and magnitude-based balance features are complementary, not redundant.

Slide 7 — Utilization Contains Signal, but the Relationship Is Non-Linear

Esta slide es deliberadamente más compleja porque utilization no tiene una historia simple.

Para average utilization change observamos aproximadamente:

[9.82, 11.30, 12.87, 14.07, 12.44, ..., 8.77%]

a través de los deciles.

Eso significa que no podemos decir:

Higher utilization change ⇒ *Higher positive concentration*

El máximo ni siquiera ocurre en el decil más alto.

Hay regiones intermedias con mayor concentración.

Esto es importante porque nuestro modelo base es Logistic Regression. Una variable continua ingresada directamente produce un efecto lineal en el log-odds:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X$$

Por eso este análisis nos advierte que el coeficiente no debe interpretarse como si el fenómeno subyacente fuera perfectamente lineal.

Después comparamos Current con Z-score.

Para average utilization:

$$\text{Corr}(\text{Current}, Z) \approx 0.631$$

cuando ambas están disponibles.

Eso implica una superposición moderada, pero no equivalencia.

El Z-score responde una pregunta distinta:

¿Es este cambio grande con respecto a la variabilidad histórica de esa misma persona?

Mientras Current responde:

¿Cuánto cambió el nivel reciente respecto al baseline?

Por eso la conclusión no es “Z es mejor”.

Es:

Z captures a different normalization of the behavior and remains a legitimate challenger.

También observamos que average utilization y weighted utilization se parecen mucho, lo cual luego aparece formalmente en la slide de redundancy.

Slide 8 — Traditional Credit-Deterioration Signals Are Weak Marginal Separators

Esta slide es muy importante desde la perspectiva conceptual del proyecto.

Si alguien viene de credit risk podría esperar:

More delinquency $\Rightarrow$ More fraud – alert vulnerability

pero nuestros resultados no muestran eso de manera marginal.

Por ejemplo, deterioration acceleration:

[Zero=9.27%] [Negative=8.04%] [Positive=7.76%]

Adverse acceleration:

[Zero=9.18%] [Negative=7.77%] [Positive=7.58%]

Y max DPD jump:

[0=9.20%] [1=7.61%] [2+=8.61%]

Por tanto, mayor deterioro crediticio no está generando una positive rate progresivamente superior.

Esto no significa que construimos mal la feature.

La interpretación depende del target.

Nuestro target es:

Future qualifying fraud alert

no:

Default

ni:

Confirmed fraud loss

Son outcomes distintos.

Esta slide demuestra precisamente por qué necesitábamos hacer feature validation en lugar de asumir que las relaciones conocidas de credit risk se transferían automáticamente al problema de fraud-alert vulnerability.

Para past due y delinquency además aparece nuevamente un fuerte availability effect.

Por tanto, la conclusión correcta es:

“Traditional delinquency deterioration has weak standalone separation for this target, while whether sufficient history exists to calculate the feature is considerably more informative.”

Slide 9 — Multiple Signals Converge Into Stronger Positive Concentration

Esta es probablemente la slide más visualmente poderosa de la presentación.

Construimos un índice descriptivo de cinco condiciones.

No es un modelo.

No es una probability score.

No está calibrado.

Solo pregunta:

¿qué ocurre cuando diferentes señales aparecen simultáneamente?

Los resultados:

[0\ signals=1.05\%][1=3.78\%][2=6.43\%][3=9.43\%][4=12.01\%][5=13.61\%]

La relación es casi perfectamente ordenada.

Comparando extremos:

$$\frac{13.61}{1.05} \approx 13$$

La positive rate descriptiva del grupo con las cinco condiciones es aproximadamente 13 veces la del grupo con cero.

También tenemos una concentración muy clara.

Los grupos de 4–5 señales contienen aproximadamente:

[55.6\%]

de la población analítica, pero:

[76.7\%]

de todos los positivos.

Por otro lado, los grupos 0–1 representan aproximadamente:

[20.3\%]

de la población, pero solamente:

[3.6\%]

de los positivos.

Sin embargo, debes enfatizar una limitación importante: las cinco condiciones no son cinco fenómenos conductuales independientes.

Tres están relacionadas con disponibilidad:

- balance availability,
- utilization availability,
- active-Z availability.

Por tanto, el mensaje correcto es:

“Multiple feature conditions converge into progressively greater positive concentration.”

No:

“Five independent fraud mechanisms multiply risk.”

Tampoco deberíamos llamar a esto “risk score”.

El propósito es demostrar que las features, juntas, contienen estructura útil.

Slide 10 — Several Feature Representations Are Highly Redundant

Aquí cambiamos de pregunta.

Hasta ahora preguntamos:

¿hay señal?

Ahora preguntamos:

¿estamos midiendo la misma señal varias veces?

Los resultados principales:

$$\text{Corr}(\text{AvgUtilChange}, \text{WeightedUtilChange}) = 0.930$$

Eso es extremadamente alto.

Por lo tanto, las dos representaciones Current de utilization contienen prácticamente el mismo patrón global.

Para los Z:

$$\text{Corr}(\text{AvgUtilZ}, \text{WeightedUtilZ}) = 0.858$$

También es alto.

Para active accounts:

$$\text{Corr}(\text{ActiveChange}, \text{ActiveZ}) = 0.806$$

cuando ambas están disponibles.

Esto sugiere que Active Z tampoco aporta una dimensión completamente distinta.

En cambio:

$$\text{Corr}(\text{AvgUtilChange}, \text{AvgUtilZ}) = 0.631$$

es moderada.

Por tanto, Current y Z utilization tienen superposición, pero todavía pueden contener información diferente.

El caso de balance es totalmente diferente:

$$\text{Corr}(\text{SignedBalance}, \text{LogAbsBalance}) = 0.054$$

Eso refuerza que dirección y magnitud son complementarias.

El objetivo de esta slide no es eliminar variables por correlación mecánicamente.

Una correlación alta no significa automáticamente:

“delete feature”.

Lo que significa es:

“there may be limited incremental information, so this representation should be challenged during model development.”

Esta es precisamente la razón por la que hablamos de **PRIMARY vs CHALLENGER**.

Slide 11 — Feature Readiness Assessment

Esta es la conclusión del reporte.

Aquí agrupamos features según la evidencia disponible hasta este momento.

PRIMARY / KEEP

`active_accounts_changed_flag` tiene una separación muy clara entre change y no-change.

`active_accounts_change_vs_baseline` conserva información de dirección/magnitud adicional.

`log1p_abs_balance_change_model` tiene una relación mucho más limpia con el outcome que el signed change solo.

`balance_change_model` sigue siendo complementario porque preserva dirección.

Availability y coverage indicators se conservan porque vimos que la observabilidad tiene una asociación material con el outcome.

Average utilization change permanece como representación Current principal.

CHALLENGER

Active Z no parece superar claramente al Current y tiene una correlación alta con él, por lo que debe demostrar incremental value posteriormente.

Average utilization Z es un challenger más interesante porque Current-vs-Z tiene una correlación solo moderada.

Weighted utilization, tanto Current como Z, presenta fuerte redundancia con average utilization.

No lo eliminamos aún; queremos que la etapa de model development confirme si añade algo.

LOW PRIORITY

Deterioration acceleration, adverse acceleration y max DPD jump presentan poca separación marginal.

Past-due change y delinquency change también parecen estar dominados por availability más que por el valor numérico propiamente dicho.

Pero **LOW PRIORITY** no significa **REMOVE**.

La decisión definitiva debe apoyarse posteriormente en comportamiento multivariado, regularización y evaluación incremental.

La conclusión general sería:

“The feature-validation analysis shows that the engineered dataset contains meaningful structure, but the signal is not uniform. The clearest evidence comes from changes in account structure, balance-change magnitude and credit-file observability. Utilization contributes additional but non-linear information, while

the selected Z-score features are better positioned as challengers than as replacements for the Current formulation. Traditional credit-deterioration features show weaker marginal separation. Based on this evidence, the feature set is ready to proceed to predictive model development.”

Slide 1 — Fraud Alert Vulnerability: Exploratory Data Analysis

Qué propósito tiene

Esta slide define el alcance del reporte.

No estamos intentando demostrar todavía que el modelo funciona. Tampoco estamos haciendo feature importance. La pregunta es anterior:

¿El analytical dataset está correctamente construido y tiene suficiente integridad para pasar a feature validation y modeling?

El EDA revisa principalmente cuatro dimensiones:

Cohort + Outcome + Temporalconstruction + Databehavior

Cómo explicarla

Yo la presentaría así:

“This first report focuses exclusively on analytical data readiness. Before evaluating engineered features or predictive models, I wanted to confirm that the analytical population, outcome definition, temporal construction, underlying behavioral history and point-in-time controls are internally consistent.”

Después puedes aclarar:

“Model performance and feature importance are intentionally outside the scope of this report.”

Esto es importante porque marca desde el principio la separación entre los tres reportes.

Qué significa “Ready for Feature Validation”

No quiere decir:

“The model is ready for production.”

Quiere decir:

“No blocking data-construction issue has been identified that would prevent us from evaluating the engineered features.”

Slide 2 — Analytical Dataset at a Glance

Esta slide responde:

¿Qué tan grande es el analytical dataset y cuál es su unidad de análisis?

Los números principales son:

688,589

parties únicos.

Dentro de ellos:

62,599

son observations con outcome positivo y:

625,990

son negatives.

Eso genera:

$\left[\frac{62,599}{688,589} \approx 9.09\% \right]$

Pero esta cifra requiere una explicación muy importante.

El 9.09% no es prevalence

La positive rate de aproximadamente 9.09% viene del diseño analítico 1:10.

Por cada caso se seleccionaron aproximadamente diez controls.

Por lo tanto:

$\left[9.09\% \neq \text{population fraud-alert prevalence} \right]$

Es simplemente:

Yo diría explícitamente:

“The 9.09% event rate should not be interpreted as real-world prevalence. It results from the analytical sampling design.”

Esto demuestra rigor y evita que alguien interprete erróneamente el sample como población.

Los 48 meses

Tenemos:

48

consecutive observation months.

Eso corresponde a 2022–2025 completos.

Lo relevante no es solo tener cuatro años. Es que no tenemos huecos de calendario.

Los 12 meses por party

Cada party tiene:

12

meses analíticos de behavioral history.

Por eso obtenemos:

$$688,589 \times 12 = 8,263,068$$

party-month observations.

Eso es exactamente lo que esperamos.

No es un número aproximado.

Los 98.05 millones de trade records

El panel mensual se construyó a partir de aproximadamente:

98.05M

trade-level observations.

Esto te ayuda a explicar la jerarquía:

Trade → Party – Month → Party

Es decir, no comenzamos directamente con 688K filas. Hubo una construcción desde información de trade-level considerablemente más granular.

Cómo cerraría la slide

“The analytical table contains one observation per party, each supported by a complete 12-month behavioral panel derived from approximately 98 million underlying trade records.”

Slide 3 — Cohort and Outcome Integrity

Esta slide responde posiblemente la pregunta de QA más básica y más importante:

¿Cada fila representa realmente una observación válida y el label está temporalmente correcto?

Aquí tenemos dos bloques.

Cohort integrity

Tenemos:

688,589 rows = 688,589 distinct parties

Por lo tanto:

duplicate party rows = 0

Además:

null party_id = 0

$$\text{null observation_date} = 0$$

$$\text{null label} = 0$$

$$\text{invalid label} = 0$$

Eso confirma que la unidad analítica está limpia.

Outcome integrity

El outcome representa un qualifying fraud alert **después de la observation date y dentro de los tres meses siguientes**.

Por eso verificamos cuatro situaciones peligrosas.

Primero:

$$\text{Positive without alert} = 0$$

No existe un positive sin evento que lo soporte.

Segundo:

$$\text{Alert} \leq \text{ObservationDate} = 0$$

No estamos usando un evento que ya había ocurrido.

Eso sería leakage.

Tercero:

$$\text{Positive alert outside 3M} = 0$$

Todos los positives corresponden al horizonte correcto.

Cuarto:

$$\text{Negative with alert inside 3M} = 0$$

No existen negatives que deberían haber sido positivos según nuestra propia definición.

Cómo explicarlo

“The analytical cohort is one-party/one-observation, and the label definition is internally consistent with the three-month prediction horizon. We found no positive observations without a qualifying event, no past events incorrectly used as future outcomes, and no negative observations containing an eligible event inside the prediction horizon.”

Lo importante

Esta slide no demuestra que la definición de business outcome sea “perfecta”.

Demuestra que:

$$\textit{implementedlabel} = \textit{intendedlabeldefinition}$$

Ese es el mensaje correcto.

Slide 4 — Continuous Calendar Coverage

La pregunta aquí es:

¿La población analítica cubre el tiempo de manera continua y uniforme?

La primera parte es positiva:

48

month-end dates consecutivos.

No hay missing calendar months.

Eso es muy importante para un diseño temporal.

Pero la segunda parte es igualmente importante:

el volumen no es uniforme.

Hay una concentración marcada en 2024, particularmente alrededor de mayo y junio.

Junio de 2024, por ejemplo, tiene un volumen mucho mayor que un mes típico.

Cómo interpretarlo

No debemos decir:

“There was a fraud spike in June 2024.”

Porque el gráfico representa:

cohort volume

no necesariamente:

fraud incidence

Además, la positive rate fue fijada aproximadamente por el sampling design.

Por eso el mensaje correcto es:

“Calendar coverage is complete, but cohort contribution varies substantially by month.”

Por qué importa

Si calculas una media global:

$\bar{x}$

los meses con mayor población tienen mayor peso.

Por ejemplo, May–June 2024 pueden influir de forma material en estadísticas agregadas.

Cómo lo presentaría

“We have full monthly coverage with no calendar gaps. However, cohort volume is not evenly distributed. May and June 2024 contribute substantially more observations, so aggregate statistics should be interpreted as party-weighted rather than month-balanced summaries.”

Ese último punto es bastante bueno frente a un manager técnico.

Slide 5 — Source History and Left-Censoring

Esta slide necesita especial cuidado porque originalmente queríamos estudiar tenure.

El problema fue descubrir que:

`person_restricted.data_date`

no representa:

customer relationship start

Representa:

source availability/load history

Por lo tanto no podemos llamarlo tenure.

Qué significa left-censoring

La fuente comienza en:

2000 – 09 – 30

Si una persona ya aparecía en el primer día disponible de la fuente, no sabemos si su verdadera historia comenzó:

- ese día,
- cinco años antes,
- diez años antes.

Solo sabemos:

“The record already existed when the observable source begins.”

Por eso hablamos de:

left censoring

EI 37.43%

Tenemos:

257,701

parties cuya primera fecha observable coincide exactamente con el inicio de la fuente.

Eso representa:

[37.43%]

de la cohorte.

Es una proporción material.

Eso significa que para más de un tercio de la población no conocemos el verdadero inicio histórico.

Las positive rates

Source-start group:

[10.91%]

Later-history group:

[8.01%]

Es una diferencia importante.

Pero no debemos decir:

“Long-tenure customers have more fraud.”

No tenemos true tenure.

Lo correcto es:

“Source-history availability is associated with the outcome.”

Puede reflejar:

- mayor credit-file depth,
- mayor tiempo observable,
- diferencias de composición,
- cohort effects,
- exposure.

Cómo presentarlo

“We initially evaluated whether customer tenure could be a confounder. The available source does not contain true relationship tenure; `data_date` reflects source history. Thirty-seven percent of the analytical population is already

present at the source boundary, creating material left-censoring. Because source-start observations also have a higher event concentration, this history effect is documented as a limitation rather than interpreted as customer tenure.”

Esta es una explicación muy sólida.

Slide 6 — Credit Exposure Differs Materially Across Groups

Esta slide cambia de data QA a **population structure**.

La pregunta es:

¿Los positivos y negativos tienen una estructura observable de crédito similar?

La respuesta es no.

En promedio:

Negative: 3.53 active accounts

Positive: 5.04 active accounts

Los positivos tienen aproximadamente:

[43%]

más active accounts en promedio.

Pero hay un hallazgo todavía más fuerte.

Zero-active history

Entre negativos:

[16.09%]

tienen cero active accounts durante todos los meses.

Entre positivos:

[1.80%]

Eso es una diferencia enorme.

Qué nos dice

Los positivos tienen, en promedio, un credit file más observable y más profundo.

Eso puede significar mayor:

credit exposure

o mayor posibilidad de observar cambios comportamentales.

Active account buckets

La positive rate aumenta rápidamente a medida que pasamos de:

$0 \rightarrow 0 - 1 \rightarrow 1 - 3 \rightarrow 3 - 5$

active accounts.

Aproximadamente:

[0\ active\approx1.1\%] [0-1\approx4.1\%] [1-3\approx10.0\%] [3-5\approx12.9\%]

y después alrededor de 5+ comienza a estabilizarse cerca de 13–13.5%.

Interpretación

No parece una relación simplemente:

more accounts $\Rightarrow$ unlimited higher concentration

Más bien:

thin file $\rightarrow$ much lower

seguido por una rápida subida y después plateau.

Qué no decir

No diría:

“Having more accounts causes fraud vulnerability.”

Solo es una asociación estructural.

Narrativa recomendada

“Positive observations have materially deeper observable credit files. The largest difference occurs between thin/no-active-file observations and those with established active credit exposure. Beyond roughly three active accounts, the positive concentration begins to plateau.”

Slide 7 — Broader Product Exposure Is Concentrated Among Positive Observations

Esta slide extiende la anterior.

Ahora no preguntamos cuántas cuentas hay, sino:

¿cuántos tipos distintos de producto aparecen en el historial?

La métrica es:

distinct account types

El resultado principal

Las personas con:

5 + *account types*

representan aproximadamente:

[40%]

de toda la población.

Pero contienen:

[59%]

de todos los positivos.

Eso muestra una concentración clara.

Interpretación

Las observations positivas tienden a tener una estructura crediticia más amplia:

greater product breadth

Eso complementa el hallazgo de la slide anterior:

more active accounts

y:

more diverse account types

ambos están asociados con el outcome.

Los códigos de account type

En la presentación aparecen códigos como:

CC, CH, AU, FX, CV.

Hay una razón para no traducirlos a nombres de productos si no tenemos un mapping autoritativo.

Es preferible decir:

“account type code”

que inventar una interpretación incorrecta.

Qué debemos evitar

No debemos comparar un código con otro y decir:

“Product CV is riskier than CC.”

Porque:

1. las categorías no son mutuamente excluyentes;
2. una misma persona puede tener varios productos;

3. pueden existir diferencias de exposure;
4. esto es EDA, no adjusted feature effect.

Cómo presentarlo

“Product breadth reinforces the exposure story. Forty percent of the analytical population has five or more distinct account types, but this group contains roughly fifty-nine percent of all positive observations. This should be interpreted as a structural credit-file difference, not yet as product-level predictive importance.”

Slide 8 — Behavioral Profiles Are Stable but Structurally Different

Esta es probablemente la slide del EDA que más interpretación requiere.

Estamos viendo los 12 meses anteriores a la observation date:

\[M-11,\dots,M0 \]

para diferentes raw behavioral metrics.

La pregunta es:

¿Vemos un deterioro claro justo antes del future alert?

La respuesta agregada es:

No hay un sharp pre-event ramp.

Active accounts

Negatives aproximadamente:

3.48 → 3.56

Positives:

4.97 → 5.10

Los positivos están siempre por encima.

Pero ambas líneas son relativamente estables.

Eso significa:

level difference

más que:

sudden recent divergence

Balance

Negatives se mantienen aproximadamente alrededor de:

$22K - 23K$

mientras positivos están alrededor de:

$27K - 28K$

De nuevo:

persistent structural difference.

No observamos una explosión de balance inmediatamente antes del outcome.

Utilization

Aquí encontramos algo interesante.

Negatives tienen utilization alrededor de:

0.34

mientras positivos están alrededor de:

0.27

Es decir, positivos tienen **menor average utilization**, no mayor.

Esto es importante porque rompe una expectativa intuitiva de credit distress.

Delinquency

Lo mismo ocurre con delinquency share.

Negatives aproximadamente:

[3%-3.4%]

Positives aproximadamente:

[1.5%-1.6%]

Otra vez:

positives ≠ more delinquent

en el raw aggregate.

Deterioration / DPD

También observamos que deterioration counts y max DPD jump no son mayores de manera evidente en positives.

Por qué esto no es contradictorio

Porque el target es:

future qualifying fraud alert

No:

future default

Ni:

confirmed fraud victimization

Por lo tanto, no deberíamos esperar necesariamente el mismo comportamiento que un credit-risk model.

Cómo explicarlo

“The raw behavioral trajectories show persistent structural differences rather than a sharp deterioration immediately before the event. Positive observations consistently have greater credit exposure and balances, but they do not show greater conventional credit distress. In fact, average utilization and delinquency levels are lower. This reinforces that the target is future fraud-alert placement rather than default.”

Muy importante: esta slide no dice que changes no importan.

Las medias poblacionales pueden ocultar:

individual changes

Por eso el Feature Validation Report evalúa:

Recent3 – Prior9

y Z-scores.

Ese es el puente perfecto al siguiente reporte.

Slide 9 — Missingness Is Structural, Not Random

Esta slide responde:

¿Los NULLs son simplemente problemas de calidad de datos?

La evidencia dice que no.

Por ejemplo, utilization availability:

Negatives:

[67.7%]

Positives:

[89.4%]

Diferencia:

+ 21.7 *percentage points*

Balance availability:

Negatives aproximadamente:

[78.2%]

Positives:

[95.9%]

Gap:

+ 17.7pp

Past due muestra una diferencia prácticamente igual.

Delinquency availability también tiene una diferencia importante.

¿Por qué una variable puede no estar disponible?

Tomemos utilization.

Para calcular utilization necesitamos algo como:

$$\frac{\text{balance}}{\text{credit limit}}$$

Si no existe una cuenta elegible o no hay límite válido, utilization no se puede calcular.

Eso no es lo mismo que:

$$\text{utilization} = 0$$

Un cero puede significar:

“the person has an eligible account with no utilization.”

Un NULL puede significar:

“there is no eligible information from which utilization can be computed.”

Son estados diferentes.

Implicación metodológica

Por eso más adelante usamos:

$$FeatureModel = 0$$

junto con:

$$FeatureAvailableFlag$$

cuando corresponde.

No porque 0 sea el valor verdadero del missing.

Sino porque el flag permite al modelo distinguir ambos estados.

Cómo lo presentaría

“Missingness is strongly structured by credit-file depth. Positive observations are substantially more likely to have computable balance, utilization and delinquency measures. Consequently, missingness cannot be treated as random, and zero values cannot be treated as equivalent to unavailable values.”

Esto prepara muy bien la slide de availability del Feature Report.

Slide 10 — Raw Distributions Are Skewed and Heavy-Tailed

Aquí preguntamos:

¿Las variables tienen distribuciones razonables para modelar directamente?

La respuesta es:

No necesariamente.

Pero eso no significa que los datos sean erróneos.

Active accounts

La mayoría de las personas tienen relativamente pocas cuentas.

Pero el máximo es:

83

Por lo tanto, la distribución tiene cola derecha.

Balance

Tenemos una distribución extremadamente skewed.

El median está alrededor de:

$\$5.4K$

P95 aproximadamente:

$\$102K$

P99:

$\$221K$

y el máximo:

$\$55.1M$

La distancia entre median y max es enorme.

Esto es exactamente el tipo de variable donde una regresión lineal directa puede ser muy sensible a extremos.

Past due

La mediana es:

0

P75 también:

0

pero hay un máximo cercano a:

$\sqrt{\$3.66M}$

Esto nos muestra una variable:

zero – inflated + heavy – tailed

Utilization

También existen observations por encima de:

1.0

e incluso un máximo de:

54.17

Pero utilization > 1 no es automáticamente un error.

Puede ocurrir cuando balance supera el credit limit.

Por tanto, no debemos hacer:

“value > 1 → delete.”

La parte fundamental: logical QA

Aunque existen extremos:

logical violations = 0

en:

8.26M

party-month rows.

Verificamos cosas como:

$$active_accounts \leq reported_accounts$$

$$rated_active \leq active$$

$$delinquent_active \leq rated_active$$

$$utilization_eligible \leq active$$

y contadores no negativos.

Todos pasaron.

Interpretación correcta

Extreme does not automatically mean invalid.

Por eso la recomendación es:

robust transformation

winsorization

log transformation

cuando tenga sentido.

No:

automatic deletion

Cómo explicarla

“The behavioral distributions are highly skewed and several are zero-inflated or heavy-tailed. However, the extreme observations do not violate the underlying logical relationships. Therefore, the issue is primarily one of robust feature representation rather than basic data corruption.”

Este punto conecta directamente con el [log1p_abs_balance_change](#) del Feature Report.

Slide 11 — Point-in-Time and Panel Integrity

Para un Senior Data Scientist, esta es probablemente una de las slides más importantes técnicamente.

La pregunta es:

¿Alguna feature pudo haber utilizado información que todavía no existía en la observation date?

Eso sería:

data leakage

Panel de 12 meses

Tenemos:

688,589

parties.

Esperamos:

$$688,589 \times 12 = 8,263,068$$

party-month rows.

Y obtenemos exactamente eso.

Además:

$$parties\ not\ 12\ months = 0$$

$$missing/duplicate\ offsets = 0$$

$$future\ feature\ months = 0$$

$$invalid\ window\ mapping = 0$$

Por lo tanto, el behavioral panel está completo.

Trade-level point-in-time

Después verificamos los:

98,051,779

trade records.

Todas estas condiciones dieron cero:

data_date > observation_date

feature_month > observation_date

effective_date > data_date

effective_date > observation_date

misaligned data month

Esto es exactamente lo que queremos.

Por qué importa tanto

Imagina que una persona tiene observation date:

2024 – 06 – 30

y accidentalmente usamos un trade cargado:

2024 – 07 – 31

El modelo estaría viendo el futuro.

Su performance posterior podría parecer mejor de lo que realmente sería operacionalmente.

Por eso:

Point – in – time integrity

es una condición esencial.

El offset 12

Aquí hay una aclaración importante.

El modelo utiliza:

$$offsets\ 0 - 11$$

como los 12 meses de features.

Existe además:

$$offset = 12$$

pero es un **SEED técnico**.

¿Por qué?

Para calcular la primera transición en M-11 necesitamos conocer el MOP del mes inmediatamente anterior.

Es decir:

$$MOP_{M-11} - MOP_{M-12}$$

Por eso necesitamos M-12 como referencia.

Pero:

$$M - 12$$

no se agrega directamente como feature.

Cómo explicarlo

“The analytical model uses 12 feature months. A thirteenth source month is retained only as a technical seed so that the first month in the analytical window has a valid prior state for transition calculations.”

Esto demuestra muy bien por qué hablamos de un diseño de 13 meses pero solo 12 meses de feature history.

Slide 12 — EDA Readiness Assessment

Esta slide no introduce información nueva.

Es una **decision slide**.

Resume cada dimensión revisada.

Analytical cohort — PASS

one party/one observation

sin duplicados.

Outcome integrity — PASS

Cero violaciones de label/horizon.

Calendar completeness — PASS

48

meses consecutivos.

Behavioral panel — PASS

12

meses completos por party.

Point-in-time integrity — PASS

0

future-data violations.

Logical consistency — PASS

0

violaciones lógicas en 8.26M party-months.

Missingness — DOCUMENTED

No ponemos PASS porque:

missingness exists and is meaningful.

Pero tampoco es un blocker.

Ya sabemos cómo debe manejarse.

Outliers — MANAGEABLE

No significa:

“there are no outliers.”

Significa:

“the extreme values are logically plausible and can be handled using robust feature engineering.”

True tenure — LIMITATION

No conocemos relationship tenure con la fuente actual.

Por lo tanto no deberíamos pretender que lo medimos.

Source left-censoring — LIMITATION

Una parte material de la población está presente desde el inicio de la fuente.

Ese límite debe mantenerse documentado.

Cómo presentar la conclusión final

Yo no terminaría diciendo simplemente:

“The data looks good.”

Eso es demasiado informal y no refleja todo el trabajo.

Usaría algo cercano a:

“The EDA did not identify any blocking issues in cohort construction, label integrity, temporal alignment, behavioral panel completeness or logical consistency. The main considerations are structural rather than data-quality failures: credit-file exposure differs materially across the outcome groups, missingness is informative, several behavioral distributions are heavy-tailed, and true customer tenure cannot be recovered from the current source. These limitations are documented and can be explicitly handled in the next stages. Based on these results, the dataset is suitable to proceed to engineered feature validation.”

Eso resume exactamente la evidencia.

El mensaje que debería llevarse tu manager

Si después de toda la presentación te preguntan:

“So, what did the EDA actually tell us?”

Yo respondería:

“It told us that the dataset is technically sound enough to model, but that the population is structurally heterogeneous. Positive observations tend to have deeper and broader observable credit exposure, missingness is strongly informative, and we do not see a simple conventional credit-deterioration ramp before the future alert. The temporal construction and point-in-time controls pass, so the next question is no longer whether the data is correctly assembled; it is whether the engineered behavioral changes can extract useful predictive signal from that structure.”

Ese cierre conecta de forma natural y muy fuerte con el **Feature Validation Report**.