Sí. Se puede, y de hecho esa métrica es distinta de la tasa mensual que vimos antes.

Aquí contaríamos **cada `party_id` una sola vez**, usando únicamente su **primera `observation_date` disponible dentro del período 2022–2025**, y luego verificamos si en esa primera observación tenía:

$$label_3m = 1$$

La lógica sería:

$$party_id \rightarrow \min(observation_date) \rightarrow label_3m \rightarrow countbymonth$$

Así evitamos que un mismo party aparezca como positivo en marzo, abril y mayo por el mismo futuro alert.

Este sería el query:

```
first_observation_label1_by_month <- sdf_sql(
  sc,
  "
  WITH population AS (

      SELECT DISTINCT
          party_id,
          data_date AS observation_date

      FROM bc3.person_restricted

      WHERE data_date >= '2022-01-01'
        AND data_date <= '2025-12-31'
        AND data_date = LAST_DAY(data_date)
  ),

  at_risk AS (

      SELECT
          p.party_id,
          p.observation_date,
          f.first_qualifying_alert_date

      FROM population p

      LEFT JOIN bu_frd.party_first_valid_alert_all f
          ON p.party_id = f.party_id
```

```
    WHERE
        f.first_qualifying_alert_date IS NULL
        OR f.first_qualifying_alert_date > p.observation_date
),

labeled AS (

    SELECT
        party_id,
        observation_date,
        first_qualifying_alert_date,

        CASE
            WHEN first_qualifying_alert_date > observation_date
             AND first_qualifying_alert_date
                 <= ADD_MONTHS(observation_date, 3)
            THEN 1
            ELSE 0
        END AS label_3m

    FROM at_risk
),

first_observation AS (

    SELECT
        party_id,
        observation_date,
        first_qualifying_alert_date,
        label_3m,

        ROW_NUMBER() OVER (
            PARTITION BY party_id
            ORDER BY observation_date
        ) AS rn

    FROM labeled
)

SELECT
    observation_date,

    YEAR(observation_date) AS observation_year,
    MONTH(observation_date) AS observation_month,

    COUNT(DISTINCT party_id) AS first_observation_label1_parties

FROM first_observation
```

```
  WHERE rn = 1
    AND label_3m = 1

  GROUP BY
      observation_date,
      YEAR(observation_date),
      MONTH(observation_date)

  ORDER BY observation_date
  "
) %>%
  collect()

first_observation_label1_by_month
```

El resultado sería algo así:

Observation Date	Year	Month	First-observation Label 1 parties
2022-01-31	2022	1	...
2022-02-28	2022	2	...
...	...	...	...
2024-05-31	2024	5	...
2024-06-30	2024	6	...

Hay una interpretación importante: aquí **“first observation” significa la primera observación del party dentro de nuestro período analítico 2022–2025**, no necesariamente la primera vez histórica que aparece en `bc3.person_restricted`.

Por ejemplo, si un party existe desde 2010 pero su primera observation considerada por este análisis es:

$$2022 - 01 - 31$$

entonces esa será su first observation para este cálculo.

Si además quieres ver el denominador —cuántos parties entraron por primera vez cada mes y qué porcentaje de ellos resultó `label_3m=1`— recomiendo sacar una tabla un poco más completa:

```
first_observation_rate_by_month <- sdf_sql(
  sc,
```

```
"
WITH population AS (

    SELECT DISTINCT
        party_id,
        data_date AS observation_date

    FROM bc3.person_restricted

    WHERE data_date >= '2022-01-01'
      AND data_date <= '2025-12-31'
      AND data_date = LAST_DAY(data_date)
),

at_risk AS (

    SELECT
        p.party_id,
        p.observation_date,
        f.first_qualifying_alert_date

    FROM population p

    LEFT JOIN bu_frd.party_first_valid_alert_all f
        ON p.party_id = f.party_id

    WHERE
        f.first_qualifying_alert_date IS NULL
        OR f.first_qualifying_alert_date > p.observation_date
),

labeled AS (

    SELECT
        party_id,
        observation_date,

        CASE
            WHEN first_qualifying_alert_date > observation_date
             AND first_qualifying_alert_date
                 <= ADD_MONTHS(observation_date, 3)
            THEN 1
            ELSE 0
        END AS label_3m

    FROM at_risk
),
```

```
  first_observation AS (

      SELECT
          party_id,
          observation_date,
          label_3m,

          ROW_NUMBER() OVER (
              PARTITION BY party_id
              ORDER BY observation_date
          ) AS rn

      FROM labeled
  )

  SELECT
      observation_date,
      YEAR(observation_date) AS observation_year,
      MONTH(observation_date) AS observation_month,

      COUNT(*) AS first_observation_parties,

      SUM(label_3m) AS first_observation_label1,

      COUNT(*) - SUM(label_3m) AS first_observation_label0,

      100.0 * SUM(label_3m) / COUNT(*) AS first_observation_outcome_rate_pct

  FROM first_observation

  WHERE rn = 1

  GROUP BY
      observation_date,
      YEAR(observation_date),
      MONTH(observation_date)

  ORDER BY observation_date
  "
) %>%
  collect()

first_observation_rate_by_month
```

Esta segunda versión me parece más útil porque no solo dirá **cuántos Label 1 entraron por primera vez**, sino también:

$$ \boxed{ \frac{\text{first-observation Label 1}} {\text{all first-observation parties}} } $$

por cada mes. Eso nos puede ayudar bastante a distinguir si el pico de 2024 se debe a que entraron más personas nuevas al universo observable o a que aumentó realmente la proporción que se convirtió en `label_3m=1`.

y el otro query que necesito es cuantos party id hay unicos por año y tambien si me puedes dar el codigo para graficar en r los queries de monthly_population_outcome_rate,annual_population_outcome_rate, first_observation_label1_by_month,irst_observation_rate_by_month y el de party id unicos por ano

Sí. Para mantener consistencia con los queries anteriores, primero sacaría **party_id únicos observables por año** desde `bc3.person_restricted`, usando los mismos month-end de 2022–2025.

```
unique_parties_by_year <- sdf_sql(
  sc,
  "
  SELECT
      YEAR(data_date) AS observation_year,
      COUNT(DISTINCT party_id) AS unique_parties

  FROM bc3.person_restricted

  WHERE data_date >= '2022-01-01'
    AND data_date <= '2025-12-31'
    AND data_date = LAST_DAY(data_date)

  GROUP BY YEAR(data_date)

  ORDER BY observation_year
  "
) %>%
  collect()

unique_parties_by_year
```

Esto responde:

> ¿Cuántos `party_id` diferentes estuvieron observables al menos una vez en cada año?

Un mismo party puede aparecer en 2022 y 2023, por lo que puede contarse una vez en cada año. No estamos diciendo que sean parties exclusivos de ese año.

Para las gráficas, te recomiendo usar `ggplot2`. Primero carga:

```
library(ggplot2)
library(dplyr)
```

```
library(scales)
```

Monthly population outcome rate

Esta es probablemente la gráfica más importante para estudiar el cambio de 2024.

```
monthly_population_outcome_rate <- monthly_population_outcome_rate %>%
  mutate(
    observation_date = as.Date(observation_date)
  )

ggplot(
  monthly_population_outcome_rate,
  aes(
    x = observation_date,
    y = outcome_rate_pct
  )
) +
  geom_line(linewidth = 1) +
  geom_point(size = 2) +
  labs(
    title = "Monthly 3-Month Outcome Rate",
    subtitle = "Full observable population before 10:1 sampling",
    x = "Observation Month",
    y = "Outcome Rate (%)"
  ) +
  scale_x_date(
    date_breaks = "3 months",
    date_labels = "%b-%Y"
  ) +
  theme_minimal() +
  theme(
    axis.text.x = element_text(
      angle = 45,
      hjust = 1
    )
  )
```

Esta gráfica responde:

$$De todos los parties at risk en cada a observation month,$$

$$¿qué porcentaje presentó su first qualifying alert en los siguientes 3 meses?$$

Annual population outcome rate

Para los cuatro años usaría barras:

```
annual_population_outcome_rate <- annual_population_outcome_rate %>%
  mutate(
    observation_year = as.factor(observation_year)
  )

ggplot(
  annual_population_outcome_rate,
  aes(
    x = observation_year,
    y = outcome_rate_pct
  )
) +
  geom_col(width = 0.65) +
  geom_text(
    aes(
      label = paste0(
        round(outcome_rate_pct, 2),
        "%"
      )
    ),
    vjust = -0.4
  ) +
  labs(
    title = "Annual 3-Month Outcome Rate",
    subtitle = "Full observable population before 10:1 sampling",
    x = "Observation Year",
    y = "Outcome Rate (%)"
  ) +
  theme_minimal()
```

Aquí podremos comparar directamente:

2022
2023
2024
2025

sin que el sampling 10:1 distorsione el porcentaje.

First-observation Label 1 parties by month

Esta gráfica muestra **cantidad**, no rate:

```
first_observation_label1_by_month <- first_observation_label1_by_month %>%
  mutate(
```

```
    observation_date = as.Date(observation_date)
  )

ggplot(
  first_observation_label1_by_month,
  aes(
    x = observation_date,
    y = first_observation_label1_parties
  )
) +
  geom_line(linewidth = 1) +
  geom_point(size = 2) +
  labs(
    title = "Label 1 Parties at First Observation by Month",
    subtitle = "Each party is counted only at its first analytical observation",
    x = "First Observation Month",
    y = "Label 1 Parties"
  ) +
  scale_x_date(
    date_breaks = "3 months",
    date_labels = "%b-%Y"
  ) +
  scale_y_continuous(
    labels = comma
  ) +
  theme_minimal() +
  theme(
    axis.text.x = element_text(
      angle = 45,
      hjust = 1
    )
  )
```

Esta será muy útil para comprobar si en el período de 2024 simplemente **entraron más Label 1 por primera vez**.

First-observation outcome rate by month

Esta es diferente a la anterior porque incluye denominador:

$$\frac{First Observation\ Label1}{All\ First Observation\ Parties}$$

```
first_observation_rate_by_month <- first_observation_rate_by_month %>%
  mutate(
    observation_date = as.Date(observation_date)
  )
```

```
ggplot(
  first_observation_rate_by_month,
  aes(
    x = observation_date,
    y = first_observation_outcome_rate_pct
  )
) +
  geom_line(linewidth = 1) +
  geom_point(size = 2) +
  labs(
    title = "Outcome Rate at First Observation by Month",
    subtitle = "Label 1 among parties entering their first analytical observation",
    x = "First Observation Month",
    y = "Outcome Rate (%)"
  ) +
  scale_x_date(
    date_breaks = "3 months",
    date_labels = "%b-%Y"
  ) +
  theme_minimal() +
  theme(
    axis.text.x = element_text(
      angle = 45,
      hjust = 1
    )
  )
```

Esta gráfica ayuda a separar dos explicaciones diferentes para 2024:

$$morenewparties$$

versus

$$higherLabel1rateamongnewparties$$

Unique party IDs by year

Para este resultado también usaría barras:

```
unique_parties_by_year <- unique_parties_by_year %>%
  mutate(
    observation_year = as.factor(observation_year)
  )
```

```
ggplot(
  unique_parties_by_year,
  aes(
    x = observation_year,
    y = unique_parties
  )
) +
  geom_col(width = 0.65) +
  geom_text(
    aes(
      label = comma(unique_parties)
    ),
    vjust = -0.4
  ) +
  scale_y_continuous(
    labels = comma
  ) +
  labs(
    title = "Unique Observable Parties by Year",
    subtitle = "Distinct party_id observed in month-end population snapshots",
    x = "Year",
    y = "Unique Parties"
  ) +
  theme_minimal()
```

Hay una interpretación que quiero que mantengamos clara al comparar estas cinco gráficas:

Gráfica	Qué mide
Monthly outcome rate	Tasa del outcome en todas las observaciones at-risk de cada mes
Annual outcome rate	Tasa del outcome en todas las observaciones at-risk del año
First-observation Label 1	Número de Label 1 en la primera observación del party
First-observation rate	Proporción de Label 1 entre parties en su primera observación
Unique parties/year	Número de consumidores distintos observables durante el año

Las dos que yo analizaría **juntas primero** para estudiar 2024 serían `monthly_population_outcome_rate` y `unique_parties_by_year`. Después usaría las dos de first observation para determinar si parte del incremento proviene de cambios en la entrada/composición de parties.

Cuando tengas los resultados de estos queries, pásamelos y podemos interpretar las cinco gráficas en conjunto y determinar exactamente qué está explicando el pico de 2024.