

Fraud Alert Vulnerability

Technical Project Reconstruction

Reconstrucción cronológica y metodológica del desarrollo validado del proyecto, dirigida a una audiencia de Data Science sin contexto previo.

Current validated state: outcome basado en la primera qualifying fraud alert observada (types 2/3), horizonte de 3 meses, diseño histórico 1 SEED + 9 PRIOR + 3 RECENT, Model A vs Model B y Logistic Regression con regularización L2.

1. Qué intenta resolver realmente el proyecto

El objetivo del proyecto Fraud Alert Vulnerability es identificar señales de deterioro o cambios en el comportamiento crediticio que aparecen antes de que una party reciba por primera vez una alerta de fraude calificante.

La distinción central es que el target no representa fraude confirmado. El modelo intenta anticipar la primera qualifying fraud alert observada, no determinar culpabilidad ni confirmar fraude.

$$Y_i = 1 \text{ si la party } i \text{ presenta su primera qualifying fraud alert; } 0 \text{ en caso contrario.}$$

Actualmente, las qualifying fraud alerts son los alert types 2 y 3. Por lo tanto, un score alto debe interpretarse como mayor similitud con patrones históricos observados antes de una qualifying fraud alert, no como evidencia de fraude confirmado.

2. Definición del outcome

2.1 Problema original

Antes de construir features había que decidir exactamente qué evento convertía una observación en CASE. Una definición demasiado amplia podía mezclar alertas repetidas, diferentes tipos de alertas y parties que ya se encontraban dentro del proceso que se quería anticipar.

2.2 Decisión final

$$T_i^{\text{fraud}} = \min\{t : \text{qualifying fraud alert de tipo 2 o 3}\}$$

Para cada party se identifica la primera aparición observada de una alerta calificante. Las alertas posteriores no generan observaciones adicionales. Esto convierte el problema en: ¿cómo se comportaba esta party antes de que apareciera por primera vez la señal que queremos anticipar?

3. Construcción de CASES y CONTROLS

3.1 CASES

Un CASE corresponde a una party cuya primera qualifying fraud alert ocurre dentro del marco temporal definido. A cada party se le asigna una única observation_date desde la cual se reconstruye el comportamiento histórico y se evalúa el horizonte de outcome.

3.2 Una sola observation_date por party

$$\text{Party}_i \rightarrow 1 \text{ observation_date}_i \rightarrow 1 \text{ row analítica}$$

Esta decisión evita que una misma party aparezca repetidamente, reduce dependencia entre observaciones y evita que parties con mayor longitud de historia dominen el entrenamiento.

3.3 CONTROLS

Los CONTROLS representan parties que no presentan la qualifying fraud alert correspondiente bajo la definición temporal del experimento. No se utilizaron todos los negativos disponibles; se realizó sampling con una razón congelada de 1 CASE : 10 CONTROLS.

$$N_{\text{control}} = 10 \times N_{\text{case}}$$

4. Por qué se utilizó una relación 1:10

El problema es altamente desbalanceado. Utilizar toda la población negativa habría incrementado fuertemente el tamaño del dataset y el costo computacional sin garantizar una mejora proporcional de información. La relación 1:10 conserva una cantidad amplia de ejemplos negativos alrededor de cada caso positivo y facilita la iteración del pipeline.

Sin embargo, esta decisión afecta la interpretación de probabilidades: la prevalencia del sample no es necesariamente la prevalencia real de producción. Por ello, $P_{sample}(Y=1 | X)$ no debe interpretarse automáticamente como $P_{population}(Y=1 | X)$ sin una etapa posterior de calibración o ajuste de prevalencia.

5. Split temporal

Dataset	Periodo	Cases	Controls
TRAIN	2022-2023	27,033	270,330
VALIDATION	2024	23,557	235,570
TEST	2025	12,009	120,090

Total = 688,589 unique parties

El proyecto utiliza una partición temporal en lugar de un random split. TRAIN se utiliza para estimar parámetros, VALIDATION para desarrollo y selección de modelo, y TEST 2025 se conserva como holdout temporal final.

La regla vigente es: TEST 2025 no ha sido utilizado para model selection.

6. Por qué temporal y no random

Un random split mezcla momentos históricos y puede producir una evaluación demasiado optimista si TRAIN y VALIDATION terminan representando prácticamente la misma distribución temporal. El escenario real exige entrenar con pasado y aplicar el modelo sobre periodos posteriores.

2022-2023 -> 2024 -> 2025

Esta secuencia crea una evaluación out-of-time más cercana al uso futuro del modelo.

7. Prediction horizon

El outcome se evalúa en los próximos 3 meses calendario posteriores a observation_date.

Historical behavior -> observation_date -> next 3 months -> outcome

La condición temporal fundamental es que las features deben utilizar únicamente información disponible hasta el cutoff definido. Información posterior implicaría leakage.

8. Diseño histórico de 13 meses

13 months = 1 SEED + 9 PRIOR + 3 RECENT

Aunque se recuperan 13 meses históricos, solamente 12 se utilizan como ventana analítica. El mes SEED existe para soportar el cálculo de la primera transición basada en LAG.

Bloque	Duración	Rol
SEED	1 mes	Soporte de primera transición
PRIOR	9 meses	Baseline histórico
RECENT	3 meses	Comportamiento próximo a

9. Por qué SEED no es una feature

La ventana analítica real es PRIOR 9 + RECENT 3 = 12 meses. SEED actúa como condición inicial para calcular el cambio del primer mes analítico.

$$\Delta x_{\text{first}} = x_{\text{first}} - x_{\text{seed}}$$

SEED no debe incluirse en promedios, ratios o agregaciones analíticas. Por ejemplo, el promedio PRIOR correcto utiliza únicamente los 9 meses PRIOR.

$$\text{mean_prior} = (1/9) \times \sum_{t \text{ in PRIOR}} x_t$$

10. Extracción de trades

Después de construir la cohorte se reconstruye el comportamiento crediticio histórico de cada party a nivel party x month, agregando información disponible de trades/accounts.

- estado de cuenta y MOP
- balances
- utilization
- delinquency y past due
- active accounts
- availability / coverage

El principio temporal es que todo dato utilizado como feature debe ser observable antes o en el cutoff correspondiente.

11. MOP transitions

Una fotografía puntual de MOP contiene información, pero el proyecto buscó capturar especialmente cómo cambia el estado crediticio. Por ello se construyeron transiciones $\text{MOP}_{\{t-1\}} \rightarrow \text{MOP}_t$ a nivel trade.

$$\text{previous_mop} = \text{LAG}(\text{mop}) \text{ over } (\text{partition by party_id, trade_id order by month})$$

El SEED permite que el primer mes PRIOR también tenga un estado previo válido. Posteriormente las transiciones se agregan a nivel party/month y luego entre PRIOR y RECENT.

12. Deterioration

Deterioration busca capturar movimientos hacia un estado peor. Conceptualmente, cuando la codificación de MOP es ordinal en la dirección esperada:

$$\text{Deterioration}_{\{i,t\}} = I(\text{MOP}_{\{i,t\}} > \text{MOP}_{\{i,t-1\}})$$

A nivel agregado puede expresarse como una tasa de transiciones deterioradas sobre transiciones elegibles. El interés no es únicamente el estado final, sino la dinámica de empeoramiento.

13. Adverse entry

Adverse entry responde si una cuenta acaba de entrar en un estado adverso.

$$\text{AdverseEntry}_t = I(\text{MOP}_{\{t-1\}} \text{ not in A AND } \text{MOP}_t \text{ in A})$$

Esto diferencia una nueva entrada a una condición problemática de una condición adversa persistente.

14. Past due y delinquency share

$$\text{DelinquencyShare}_t = N_{\text{delinquent},t} / N_{\text{eligible},t}$$

Esta métrica distingue entre una delinquency aislada y una afectación amplia del portafolio. Por ejemplo, 2 cuentas delinquent de 5 cuentas elegibles producen una delinquency share de 0.40.

15. Utilization

$$\text{Utilization} = \text{Balance} / \text{CreditLimit}$$

La utilización expresa cuánto del límite disponible está siendo utilizado. El proyecto trabaja, entre otras señales, con average utilization y weighted utilization. El promedio simple pondera cada trade por igual; una versión weighted asigna mayor peso según la exposición definida.

16. Balance

Balance es una variable monetaria con distribución usualmente asimétrica y cola derecha extensa. Esta propiedad fue importante al evaluar si una transformación Z-score representaba adecuadamente el fenómeno o si convenía una transformación de magnitud.

17. Active accounts

active_accounts representa el número de trades/cuentas activas. Cambios en esta cantidad pueden ser informativos incluso cuando otras métricas se mantienen similares, lo cual motivó incorporar un flag explícito de cambio.

18. Availability / coverage

La disponibilidad de información también puede contener señal. No todas las parties tienen el mismo número de trades, los mismos meses observados ni idéntica cobertura histórica. Por ello se conservaron variables de availability/coverage en vez de tratarlas únicamente como un problema de missingness.

Esto ayuda a distinguir valor cero por ausencia real del fenómeno versus ausencia de información suficiente.

19. Cambio desde nivel absoluto hacia comportamiento

La hipótesis principal del feature engineering es que la vulnerabilidad puede estar contenida en el cambio reciente, no únicamente en el nivel absoluto. Por eso se compara RECENT 3m contra PRIOR 9m.

$$\text{Delta } x = \text{mean_recent} - \text{mean_prior}$$

20. Por qué 3 meses recientes contra 9 meses previos

Los nueve meses PRIOR proporcionan un baseline relativamente estable; los tres meses RECENT representan el comportamiento más cercano a observation_date.

$$\text{mean_prior} = (1/9) \text{ sum PRIOR}; \text{mean_recent} = (1/3) \text{ sum RECENT}$$

Ejemplo: si utilization promedio PRIOR es 40.4% y RECENT es 62%, el cambio es 21.6 puntos porcentuales. La feature expresa un deterioro relativo a la propia historia de la party, no sólo el nivel 62%.

21. Current Formula

El enfoque principal utiliza a la propia party como baseline. De manera general:

$$\text{CurrentFeature} = f(\text{Recent}, \text{Prior})$$

El caso más simple es $\text{mean_recent} - \text{mean_prior}$. Para otras variables pueden ser más apropiados ratios, flags, diferencias de tasas o transformaciones de magnitud. No se debe forzar una sola fórmula a todas las variables.

22. Qué problema intentaba resolver Z-score

$$Z = (\text{mean_recent} - \text{mean_prior}) / s_{\text{prior}}$$

Z-score intenta medir qué tan extraordinario es el cambio reciente comparado con la variabilidad histórica propia de la party. El numerador mide desplazamiento; el denominador mide volatilidad histórica.

23. Ejemplo Current vs Z-score

Party A: historial estable

PRIOR alrededor de 40 con desviación estándar aproximada de 0.7; RECENT = 46. El cambio Current es 6, y el Z-score aproximado es 8.57. El cambio es excepcional respecto a su historia.

Party B: historial volátil

PRIOR también con promedio 40 pero desviación estándar aproximada de 18; RECENT = 46. El cambio Current vuelve a ser 6, pero el Z-score es aproximadamente 0.33. El mismo cambio absoluto es poco extraordinario para esta party.

24. Por qué Z-score no reemplaza automáticamente Current

Z-score puede ser frágil cuando la desviación estándar histórica es cero o muy pequeña. Si PRIOR es constante, $s_{\text{prior}} = 0$ y el Z-score clásico no está definido. Por ello se trató como challenger feature family y no como sustitución universal del enfoque Current.

25. Evaluación variable por variable de Z-score

Familia	Resultado
Active accounts	Selected Z
Average utilization	Selected Z
Weighted utilization	Selected Z
Balance	Not selected for Z
Deterioration	Not selected for Z
Adverse	Not selected for Z
Past due	Not selected for Z
Delinquency share	Not selected for Z

No seleccionar Z para una variable no significa eliminar la variable original. Significa que su representación Z no aportó suficiente justificación para entrar al challenger final.

26. Por qué una variable puede funcionar con Current y no con Z

Current y Z responden preguntas distintas. Current pregunta cuánto cambió; Z pregunta cuánto cambió en unidades de su propia volatilidad histórica. Una variable predictiva en su forma original no tiene por qué ser predictiva después de esta transformación.

27. Balance y transformación de magnitud

Balance puede estar dominado por escala, outliers, skewness y exposición financiera. Por ello se exploraron transformaciones que capturan magnitud sin permitir que la cola extrema domine completamente el modelo.

28. log1p_abs_balance_change

$$\begin{aligned}\text{DeltaBalance} &= \text{Balance_recent} - \text{Balance_prior} \\ \log1p_abs_balance_change &= \log(1 + |\text{DeltaBalance}|)\end{aligned}$$

El valor absoluto captura magnitud del cambio independientemente de dirección. log1p comprime la cola, mantiene orden relativo y permite manejar cambio cero porque $\log(1+0)=0$.

29. active_accounts_changed_flag

$$\text{Flag} = I(\text{ActiveAccounts_recent} \neq \text{ActiveAccounts_prior})$$

El flag separa la existencia de un cambio estructural de su magnitud. Por ejemplo, 4->5 y 4->9 producen Flag=1 aunque el cambio absoluto sea distinto.

30. Qué aprendimos del análisis univariado

El análisis univariado se utilizó para entender disponibilidad, distribución, separación CASES vs CONTROLS, skewness, outliers, estabilidad temporal y comportamiento de transformaciones. Sin embargo, una variable interesante de forma univariada no es necesariamente útil multivariadamente, porque puede ser redundante con otras features.

31. Qué aprendimos sobre availability

Availability se evaluó no sólo como missing rate sino como posible patrón informativo. Si la cobertura histórica difiere sistemáticamente entre CASES y CONTROLS, esta información puede ayudar al modelo a contextualizar otras variables.

32. Feature engineering final

Behavioral Current features

- active accounts

- average utilization
- weighted utilization
- balances
- deterioration
- adverse behavior
- past due
- delinquency share

Coverage / availability

Señales que describen cantidad y calidad de información disponible por party.

Validated transformations

- active_accounts_changed_flag
- log1p_abs_balance_change

Z-score challengers

- Z active accounts
- Z average utilization
- Z weighted utilization

33. Model A

Model A = Current behavioral features + Availability/Coverage + Validated transformations

Model A representa el baseline de features validado. No incorpora la familia Z seleccionada como extensión adicional.

34. Model B

Model B = Model A + Selected Z

Selected Z contiene active accounts, average utilization y weighted utilization. Esta construcción permite medir valor incremental de Z manteniendo el resto del diseño constante.

35. Por qué la comparación A/B es metodológicamente fuerte

Si $B = A + Z$, cualquier mejora puede atribuirse con mayor claridad al valor incremental de las features Z. Una comparación entre modelos radicalmente diferentes no permitiría aislar esa contribución.

36. Algoritmo baseline: Logistic Regression con L2

$$P(Y=1|X) = 1 / (1 + \exp(-(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)))$$

$$\log(p/(1-p)) = \beta_0 + \sum_j \beta_j x_j$$

La Logistic Regression proporciona un baseline interpretable, rápido y estable para comparar feature sets. La regularización L2 reduce coeficientes excesivamente grandes y mejora estabilidad cuando existen features correlacionadas.

37. Qué hace L2

$$\text{Loss_L2} = \text{Loss_logistic} + \text{lambda} * \sum_j \text{beta_j}^2$$

L2 penaliza magnitudes elevadas de coeficientes. A diferencia de L1, normalmente no lleva coeficientes exactamente a cero; más bien los reduce.

38. TRAIN, VALIDATION y TEST

TRAIN 2022-2023

27,033 cases y 270,330 controls. Se utiliza para fit de preprocessing cuando corresponda, estimación de coeficientes y entrenamiento.

VALIDATION 2024

23,557 cases y 235,570 controls. Se utiliza como out-of-time development set para comparar Model A vs Model B, evaluar transformaciones y tomar decisiones de selección.

TEST 2025

12,009 cases y 120,090 controls. Debe mantenerse aislado hasta que preprocessing, features e hiperparámetros estén congelados. No ha sido utilizado para model selection.

39. Por qué no optimizar viendo TEST

Si se consulta TEST durante múltiples iteraciones, aunque no se entrene con él, las decisiones humanas comienzan a adaptarse a su resultado. Esto lo convierte indirectamente en development data y elimina su valor como evaluación final independiente.

TRAIN -> fit; VALIDATION -> selection; TEST -> final unbiased evaluation

40. Discovery vs decisiones congeladas

Discovery / exploración

- distintas representaciones de cambio
- Current vs Z-score
- distribuciones y outliers
- availability
- transformaciones para balance
- flags para active accounts

Decisiones congeladas

- Outcome = first observed qualifying fraud alert, types 2/3
- Prediction horizon = próximos 3 meses calendario
- 1 SEED + 9 PRIOR + 3 RECENT
- SEED no es feature
- 688,589 unique parties
- Sampling 1:10
- TRAIN 2022-2023 / VALIDATION 2024 / TEST 2025

- Model A y Model B definidos para comparación
- Logistic Regression con L2 como baseline

41. Flujo end-to-end del proyecto

1) Raw fraud alert history -> 2) identificar first qualifying alert types 2/3 -> 3) construir CASES/CONTROLS -> 4) asignar una observation_date por party -> 5) split temporal -> 6) sampling 1:10 -> 7) recuperar 13 meses históricos -> 8) separar SEED/PRIOR/RECENT -> 9) extraer trades y MOP -> 10) construir transitions -> 11) agregar behavioral features -> 12) evaluar Current, availability, transformations y Z -> 13) definir Model A/B -> 14) entrenar Logistic Regression L2 -> 15) seleccionar con VALIDATION -> 16) evaluar finalmente en TEST.

42. Ejemplo completo con una party

Supongamos una observation_date al cierre de agosto de 2024. El outcome se busca en los siguientes 3 meses calendario. Para active_accounts, supongamos PRIOR = nueve meses con valor 3 y RECENT = 4, 4, 5.

PriorMean = 3; RecentMean = $(4+4+5)/3 = 4.33$; Current change = 1.33

active_accounts_changed_flag = 1

Como PRIOR es completamente constante, s_prior = 0. El Z-score clásico no sería directamente calculable, ilustrando por qué esta familia debe manejar edge cases explícitamente.

43. Interpretación científica de Current vs Z

Representación	Pregunta
Nivel reciente	¿Dónde está la party ahora?
Current change	¿Cuánto cambió contra su baseline?
Z-score	¿Qué tan extraordinario es ese cambio vs su variabilidad histórica?

Estas representaciones no son sustitutos perfectos; describen dimensiones distintas del comportamiento.

44. Qué significa que Model B mejore o no mejore

Si Model B supera consistentemente a Model A en VALIDATION, la lectura adecuada es que los selected Z aportan información incremental. Si el rendimiento es prácticamente igual, probablemente son redundantes frente a las features Current existentes. Si empeora, pueden estar introduciendo ruido o inestabilidad.

45. Qué no puede concluirse todavía

- Que Model B sea definitivamente el modelo final.
- Que Z-score deba utilizarse en producción.
- Que Logistic Regression sea necesariamente el algoritmo final.
- Que los scores sean probabilidades de fraude confirmado.
- Que TEST demuestre superioridad de una selección antes de congelar el diseño.

46. Trabajo todavía pendiente

- Terminar la comparación formal A vs B utilizando VALIDATION.

- Congelar preprocessing, feature set e hiperparámetros.
- Verificar estabilidad de coeficientes y signs.
- Estudiar multicollinearity y redundancia.
- Evaluar performance por segmentos de coverage cuando corresponda.
- Seleccionar operating threshold si el caso de negocio lo requiere.
- Evaluar calibration si se requieren probabilidades interpretables.
- Evaluar el modelo congelado una única vez en TEST 2025.
- Realizar análisis de temporal stability.
- Documentar limitaciones del outcome y del sampling antes de uso operacional.

47. Estado validado final

Componente	Estado
Outcome = first observed qualifying alert	Validado
Alert types 2/3	Definición vigente
One observation date per party	Validado
1:10 sampling	Validado
TRAIN 2022-2023 / VALIDATION 2024 / TEST 2025	Validado
13 months = 1 SEED + 9 PRIOR + 3 RECENT	Validado
SEED excluded from analytical features	Validado
Availability features	Incluidas en Model A
active_accounts_changed_flag	Transformación validada
log1p_abs_balance_change	Transformación validada
Selected Z: active accounts / avg util / weighted util	Challenger seleccionado
Z balance / deterioration / adverse / past due / delinquency share	No seleccionado
Logistic Regression L2	Baseline actual
TEST 2025 for model selection	No utilizado

48. Resumen ejecutivo técnico

Para cada party se construye una única observation_date y se reconstruyen 12 meses analíticos de comportamiento crediticio, apoyándose en un decimotercer mes SEED para calcular correctamente la primera transición. Los tres meses recientes se comparan contra nueve meses previos para capturar cambios conductuales antes de la primera qualifying fraud alert de tipo 2/3 observada en los siguientes tres meses. Model A contiene Current features, availability/coverage y transformaciones validadas. Model B añade únicamente los selected Z-scores. Ambos se comparan utilizando Logistic Regression con regularización L2 bajo una separación temporal estricta TRAIN 2022-2023, VALIDATION 2024 y TEST 2025.

49. Principios que un nuevo Data Scientist no debe romper

- El target no es fraude confirmado; es la primera qualifying fraud alert observada.
- La unidad analítica es una party, una sola vez.
- El diseño temporal SEED + PRIOR + RECENT forma parte de la definición científica del modelo.
- Current y Z-score responden preguntas diferentes; Z es un challenger, no una sustitución automática.
- TEST 2025 debe permanecer aislado hasta congelar completamente las decisiones del modelo.

50. Snapshot del estado vigente

Horizon: next 3 calendar months

History: 13m = 1 SEED + 9 PRIOR + 3 RECENT

Analytical features: 12m = 9 PRIOR + 3 RECENT

Population: 688,589 unique parties | Sampling: 1:10

Model A = Current + Availability + Validated transformations

Model B = Model A + selected Z

Selected Z = active accounts, avg utilization, weighted utilization

Algorithm = Logistic Regression with L2

TEST 2025 has not been used for model selection

Nota de rigor: este reporte reproduce únicamente el estado validado disponible del proyecto. No incorpora métricas, metodologías ni resultados provenientes de presentaciones de ejemplo, y evita inventar resultados univariados, coeficientes o métricas no preservadas en el estado validado.