

INFORME DE DIAGNÓSTICO

Tenure hasta la primera alerta y hoja de ruta para un índice de propensión a alerta de fraude

Proyecto de Data Science - Spark / Hive

Documento estructurado para publicación en Confluence

Estado del análisis

Diagnóstico exploratorio basado en la cohorte de primeras alertas 2022-2025. Los resultados permiten definir la siguiente fase del índice, pero todavía no permiten afirmar causalidad ni “riesgo de fraude” sin construir el denominador de personas expuestas y validar el significado del evento de alerta.

Preparado: 10 de agosto de 2026

Resumen ejecutivo

6.66 M	66,643	44.6%	37,492
Personas en cohorte 2022-2025	Muestra determinística ~1%	Inicio observado en frontera 2000	Casos válidos no censurados

Conclusión principal. El tenure es útil como variable de contexto y segmentación, pero los resultados muestran un fuerte efecto de cohorte. El pico agregado de alertas alrededor de 17-19 años no debe interpretarse como un “momento de mayor riesgo” porque, al separar por año de alerta, el pico se desplaza aproximadamente 12 meses por cada año calendario. Esto es consistente con una cohorte numerosa de clientes que envejece en el tiempo.

- **Fuente de alertas:** 324.3 millones de filas; tras deduplicar snapshots quedan 42.3 millones de eventos de creación y 29.8 millones de parties con alerta.
- **Cohorte de estudio:** 6,663,521 personas cuya primera alerta observada se ubica entre 2022 y 2025; 98.1% inicia con tipo [2].
- **Calidad del join:** 100% de cobertura en la muestra contra person_restricted.
- **Censura izquierda:** 29,086 de 66,643 personas tienen relationship_start_date exactamente en 2000-09-30, fecha mínima global de person_restricted. Deben tratarse como clientes preexistentes, no como inicios reales.
- **Tenure corregido:** en los 37,492 casos válidos y no censurados, mediana 195 meses (16.3 años), P25 121 meses (10.1 años), P75 230 meses (19.2 años).
- **Próximo paso del índice:** construir un panel de observación con población positiva y negativa, features recientes de 3/6 meses contra baseline de 12 meses, y labels 1/3/6/12 meses. Label_3m debe ser candidato principal y label_6m challenger; la selección final debe ser empírica.

Nombre recomendado mientras se valida el outcome

Hasta que exista evidencia que conecte la alerta con victimización confirmada, el modelo debe describirse como un índice de propensión/vulnerabilidad a colocar una alerta de fraude, no como probabilidad de ser víctima de fraude.

1. Objetivo y pregunta de negocio

El objetivo de esta fase fue entender cuánto tiempo transcurre entre el inicio observado de la relación de una persona y su primera alerta, y evaluar si ese tenure puede aportar información útil para un futuro índice que identifique usuarios con mayor propensión a colocar una alerta de fraude.

- Determinar la primera alerta observada por party_id sin contar snapshots repetidos.
- Estimar el inicio de relación con MIN(data_date) de person_restricted.
- Identificar problemas de calidad y censura histórica.
- Describir la distribución del tenure hasta la primera alerta.
- Separar efecto de tenure de efecto de cohorte/calendario.
- Definir el diseño mínimo requerido para pasar de análisis descriptivo a un índice predictivo.

Pregunta que sí responde esta fase

“¿Después de cuánto tiempo de relación tienden a aparecer las primeras alertas entre quienes sí colocaron una alerta y cuyo inicio puede observarse?”

Pregunta que todavía NO responde

“¿En qué tenure existe mayor probabilidad de colocar una alerta?” Para responderla se necesita el denominador: personas elegibles/expuestas en cada tenure, incluyendo quienes nunca colocaron una alerta.

2. Fuentes de datos y escala

2.1 Fuente de alertas

Métrica	Resultado
Filas fuente	324,268,295
Parties aproximados	31,916,677
MIN(crát_dte)	2007-01-13
MAX(crát_dte)	2026-07-30
MIN(data_date)	2009-03-31
MAX(data_date)	2026-07-31

Tipo de alerta	Filas snapshot	Parties aprox.
1	6,104,988	704,768
2	225,911,402	29,307,000
3	92,029,689	2,223,649
4	173,828	21,469
5	5,568	497
6	42,820	4,140

La fuente está dominada por los tipos 2 y 3. La tabla de lookup presentada en el análisis identifica el tipo 2 como Initial Fraud Alert y el tipo 3 como Extended Fraud Alert. La semántica exacta de las múltiples fechas crát_dte debe validarse con el dueño del dato antes del modelado final.

2.2 Fuente para relationship start

Métrica	Resultado
Tabla	bc3.person_restricted
Filas	59,554,936,100 (~59.55 B)
MIN(data_date)	2000-09-30
MAX(data_date)	2026-07-31
Uso en esta fase	party_id + MIN(data_date) solamente

Principio de minimización de datos

Para calcular tenure no se necesitan nombre, apellido, SSN, dirección ni otras columnas de PII. La arquitectura debe proyectar solo party_id y fechas/atributos estrictamente necesarios.

3. Metodología ejecutada

- 1. **Perfil de security_alert:** Validación de volumen, fechas y distribución por tipo.
- 2. **Deduplicación de snapshots:** Una fila por party_id + alert_create_date.
- 3. **Secuencia de alertas:** Clasificación en primera observada, creación dentro de 7 años y creación después de 7 años.
- 4. **Primera alerta observada:** Selección de la fecha más antigua por party_id.
- 5. **Cohorte 2022-2025:** Personas cuya primera alerta observada cae dentro del periodo de estudio.
- 6. **Muestra determinística:** Hash por party_id para aproximar 1% y validar la lógica sin procesar el universo completo.
- 7. **Inicio de relación:** MIN(data_date) por party_id en person_restricted.
- 8. **Cálculo de tenure:** Meses completos entre relationship_start_date y first_alert_date.
- 9. **Censura izquierda:** Flag para personas ancladas a la fecha mínima global de la fuente.
- 10. **Distribución comparable:** Bandas iguales de 12 meses y comparación por año de alerta.




Figura 1. Reducción del volumen a través del pipeline de diagnóstico (escala logarítmica).

4. Resultados

4.1 Reducción y unicidad de eventos

Etapa		Volumen	
Filas security_alert		324,268,295	
Eventos únicos party_id + alert_create_date		42,318,245	

Etapas	Volumen
Parties con alerta	29,766,492
Cohorte primera alerta 2022-2025	6,663,521
Muestra determinística	66,643
Casos válidos no censurados	37,492

La validación de unicidad posterior a la deduplicación devolvió 0 filas duplicadas para party_id + alert_create_date. Esto confirma que la reducción de snapshots funcionó según lo esperado.

4.2 Regla de 7 años: hallazgo pendiente

Estado de secuencia	Eventos
FIRST_OBSERVED_ALERT	29,766,492
CREATION_WITHIN_7_YEARS	10,951,174
CREATION_AFTER_7_YEARS	1,600,579

Hallazgo crítico

Existen 10.95 millones de fechas de creación adicionales dentro de los 7 años, a pesar de la regla de negocio de que un party_id no debería colocar otra alerta en ese periodo. Esto sugiere que una nueva crat_dte puede representar actualización, extensión, recreación técnica u otra transición, y no necesariamente un evento independiente.

Para tenure hasta la primera alerta, este hallazgo no invalida el cálculo porque se conserva la fecha más antigua. Para labels futuros y medición de eventos, sí debe resolverse antes de producción.

4.3 Cohorte de primera alerta 2022-2025

first_alert_type_set	Parties	Participación aprox.
[2]	6,538,126	98.12%
[3]	122,420	1.84%
[2,3]	2,975	0.04%

Año	Parties en muestra
2022	15,735
2023	14,195
2024	24,169
2025	12,544

La muestra total fue 66,643, consistente con una selección determinística de aproximadamente 1% del universo de la cohorte.

4.4 Cobertura del join y calidad del tenure

66,643	66,643	0	100%
Sampled alert parties	Encontrados en person_restricted	No encontrados	Cobertura del join

tenure_quality_status	Parties
VALID	66,577
START_AFTER_ALERT	65
SAME_DAY_START_AND_ALERT	1

La consistencia del join es alta. Los 65 casos START_AFTER_ALERT (~0.10%) deben conservarse como excepciones de calidad y excluirse del análisis principal de tenure.

4.5 Censura izquierda en person_restricted




Figura 2. Año mínimo observado de relación dentro de la muestra.

Indicador	Resultado
Fecha mínima global de person_restricted	2000-09-30
Parties con relationship_start_date = 2000-09-30	29,086

Indicador	Resultado
Parties cuyo start_year = 2000	29,746
Participación del año 2000 en la muestra	44.63%

Interpretación

El pico de 2000 es un efecto de frontera histórica. Para esas personas solo sabemos que ya existían cuando comienza la historia disponible; no conocemos su tenure real. Se creó left_censored_flag y el análisis de tenure confiable utiliza left_censored_flag = 0.

4.6 Tenure corregido después de excluir censura y anomalías

Estadístico	Meses	Años aprox.
N válido	37,492	-
Mínimo	0	0.0
P10	61	5.1
P25	121	10.1
Promedio	175.23	14.6
Mediana (P50)	195	16.3
P75	230	19.2
P90	257	21.4
P95	270	22.5
Máximo	299	24.9

La corrección reduce la mediana desde 255 a 195 meses y el promedio desde 220.6 a 175.2 meses. Aun así, la población alertada se concentra en relaciones de larga duración. Esto confirma que tenure debe analizarse en años y no únicamente en ventanas de 3-12 meses.

4.7 Distribución en bandas iguales de 12 meses




Figura 3. Distribución del tenure al momento de la primera alerta observada; bandas iguales de 12 meses.

- **Primeros 5 años:** 9.6% de las primeras alertas observadas.
- **Primeros 10 años:** 24.5% acumulado.
- **10-19 años:** 56.2% de la muestra válida no censurada.
- **15-19 años:** 39.2% de la muestra.
- **17-19 años aprox. (204-227 meses):** 18.2% de la muestra; es el máximo agregado.

4.8 Validación por año de alerta: evidencia de efecto de cohorte




Figura 4. Distribución del tenure dentro de cada año de alerta.

Año de alerta	Banda con mayor concentración	% dentro del año
2022	180-191 meses (~15-16 años)	12.39%
2023	192-203 meses (~16-17 años)	11.93%
2024	204-215 meses (~17-18 años)	11.74%
2025	216-227 meses (~18-19 años)	10.20%

Resultado más importante del diagnóstico

El pico se desplaza aproximadamente 12 meses por cada año calendario. Esto es consistente con una cohorte de clientes que envejece en el tiempo. Por lo tanto, el pico de 17-19 años no debe interpretarse como evidencia de que “a los 18 años aumenta el riesgo”.

5. Interpretación: qué sabemos y qué no sabemos

5.1 Conclusiones soportadas por los datos

- Entre las personas que colocaron una primera alerta y cuyo inicio es observable, el tenure típico es largo: mediana ~16.3 años.
- El volumen absoluto de alertas aumenta hacia los tenures altos y alcanza su máximo agregado alrededor de 17-19 años.
- La estabilidad anual revela que el máximo es fuertemente dependiente de la cohorte de inicio; el mismo “bulto” se mueve un año cada año calendario.
- Los primeros 1-2 años representan una fracción pequeña del volumen observado de primeras alertas.
- El tenure sigue siendo útil, pero debe coexistir con start cohort, periodo calendario y comportamiento reciente.

5.2 Lo que todavía no puede afirmarse

- No puede afirmarse que 16, 17 o 18 años sea el tenure de mayor riesgo sin conocer cuántas personas están expuestas en cada tenure.
- No puede afirmarse que el alert_create_date adicional represente una nueva victimización mientras no se resuelva la semántica de los eventos dentro de 7 años.
- No puede llamarse al modelo “probabilidad de ser víctima de fraude” si el outcome disponible es “colocación de una alerta”.
- No se debe usar el volumen absoluto como sustituto de una tasa de incidencia.

6. Hoja de ruta para crear el índice

La siguiente fase debe cambiar el enfoque desde “quién colocó una alerta y después de cuánto tiempo” hacia “qué señales estaban disponibles antes de la alerta y con qué frecuencia ocurre la alerta entre todas las personas expuestas”.

Paso 0 - Congelar la definición del outcome

Confirmar qué tipos representan una nueva colocación de alerta, qué significa una crat_dte dentro de los 7 años y si el tipo 3 es extensión del tipo 2 o un outcome separado. El label debe usar solamente eventos que negocio considere nuevos y válidos.

Paso 1 - Construir el denominador por tenure

Para cada fecha de observación, contar personas elegibles por banda de tenure y nuevas alertas. Esto permite calcular $\text{alert_rate} = \text{nuevas_alertas} / \text{personas_expuestas}$ y separar riesgo de volumen/cohorte.

Paso 2 - Crear el panel de observaciones

Una fila por party_id y observation_date, siempre anterior a la primera alerta. Si las fuentes de features actualizan mensualmente, usar panel mensual; si la frescura real es trimestral, iniciar con quarter-end para evitar meses sintéticos.

Paso 3 - Features conductuales

Usar un baseline de al menos 12 meses y ventanas recientes de 3 y 6 meses. Priorizar cambios contra el propio historial: desviaciones, tendencias, aceleraciones, volatilidad, número de señales que cambian a la vez y recencia de eventos.

Paso 4 - Tenure como contexto, no como señal única

Incluir tenure_months, tenure_band y relationship_start_cohort por separado. Probar interacciones con comportamiento reciente. No asumir relación lineal.

Paso 5 - Construir labels múltiples

Crear label_1m, label_3m, label_6m y label_12m: alerta válida dentro de la ventana futura. El candidato operativo inicial es label_3m; label_6m debe funcionar como challenger. La selección final depende de volumen positivo, estabilidad y tiempo de intervención.

Paso 6 - Controles / negativos comparables

Para cada observación positiva, comparar con personas sin alerta todavía y tenure/cohorte/producto comparables. Evitar que el modelo aprenda únicamente antigüedad o composición de la población.

Paso 7 - Gap de producción y leakage

Features deben terminar antes de observation_date según la latencia real de datos. Nunca incluir datos creados después del punto de scoring ni campos derivados de la alerta.

Paso 8 - Validación temporal

Entrenar en periodos anteriores y validar en periodos posteriores. No usar split aleatorio como validación principal.

Paso 9 - Modelos y calibración

Comenzar con regresión logística como benchmark interpretable y comparar con un modelo de árboles/boosting. Convertir la probabilidad calibrada de alerta futura en un índice 0-100 solamente después de validar calibración y estabilidad.

Paso 10 - Gobernanza

Excluir características protegidas y revisar proxies. El índice debe usarse para flujos preventivos/deber de cuidado, no para restringir crédito o acceso. Mantener trazabilidad de features, versión del modelo, periodo y razón del score.

6.1 Arquitectura propuesta del dataset de modelado

Bloque	Campos / ejemplos	Propósito
Identidad técnica	party_id	Join; no usar PII como feature
Tiempo	observation_date, relationship_start_date, tenure_months, cohort_year	Contexto temporal
Baseline 12m	promedios, tasas, frecuencia, estabilidad	Comportamiento normal individual

Bloque	Campos / ejemplos	Propósito
Reciente 3m / 6m	conteos, tasas, cambios, recencia	Señal cercana al evento
Deltas	recent_3m - baseline_12m, ratios, slope	Cambio vs. propio historial
Convergencia	número de dominios/señales elevadas	Reducir dependencia de una sola señal
Labels	label_1m, label_3m, label_6m, label_12m	Comparar horizonte de intervención
Calidad	left_censored_flag, data_availability, gap_ok	Exclusión/control de calidad

6.2 Recomendación de ventanas temporales para el primer experimento

Componente	Recomendación inicial	Motivo
Baseline	12 meses	Mínimo razonable para representar historial; con snapshots trimestrales equivale a ~4 observaciones.
Ventana reciente 1	3 meses	Señal muy cercana al evento; útil para intervención temprana.
Ventana reciente 2	6 meses	Challenger más estable para cambios graduales.
Label principal candidato	3 meses	Balance entre anticipación y densidad de positivos; debe validarse.
Labels challengers	1, 6 y 12 meses	Permiten decidir empíricamente el horizonte óptimo.
Tenure	Continuo + bandas + cohort_year	Contexto/segmentación; controlar efecto de cohorte.

Diseño conceptual del score

Vulnerability/Alert Index (0-100) = transformación de una probabilidad calibrada de “primera alerta válida dentro de los próximos N meses”. Los umbrales de Low / Moderate / High / Critical deben definirse por precisión, recall, capacidad operativa y costo de intervención; no por cortes arbitrarios de 25 puntos.

7. SQL de referencia para la siguiente fase

Los siguientes bloques son esqueletos para orientar la implementación. Deben adaptarse a las tablas reales de atributos y a la frecuencia efectiva de actualización.

A. Censura izquierda

```
-- 1) Flag de censura histórica
CREATE TABLE bu_frd.party_alert_tenure_sample_censored
USING PARQUET AS
SELECT t.*,
       CASE WHEN relationship_start_date = DATE('2000-09-30')
            THEN 1 ELSE 0 END AS left_censored_flag
FROM bu_frd.party_alert_tenure_sample t;
```

B. Labels 1/3/6/12 meses

```
-- 2) Ejemplo conceptual de labels futuros
SELECT
  u.party_id,
  u.observation_date,
  u.tenure_months,
  CASE WHEN a.first_alert_date > u.observation_date
        AND a.first_alert_date <= add_months(u.observation_date, 1)
    THEN 1 ELSE 0 END AS label_1m,
  CASE WHEN a.first_alert_date > u.observation_date
        AND a.first_alert_date <= add_months(u.observation_date, 3)
    THEN 1 ELSE 0 END AS label_3m,
  CASE WHEN a.first_alert_date > u.observation_date
        AND a.first_alert_date <= add_months(u.observation_date, 6)
    THEN 1 ELSE 0 END AS label_6m,
  CASE WHEN a.first_alert_date > u.observation_date
        AND a.first_alert_date <= add_months(u.observation_date, 12)
    THEN 1 ELSE 0 END AS label_12m
FROM observation_universe u
LEFT JOIN party_first_valid_alert a
  ON u.party_id = a.party_id
WHERE a.first_alert_date IS NULL
      OR u.observation_date < a.first_alert_date;
```

C. Volumen vs. tasa

```
-- 3) Tasa de alerta por tenure: el denominador que falta
SELECT
  alert_year,
  tenure_band,
  COUNT(*) AS exposed_parties,
  SUM(label_3m) AS new_alerts_3m,
  SUM(label_3m) / COUNT(*) AS alert_rate_3m
FROM modeling_panel
GROUP BY alert_year, tenure_band;
```

8. Criterios de decisión antes de modelar

Gate	Criterio para avanzar
Definición de evento	Reglas claras para tipos 2/3 y crat_dte dentro de 7 años.
Cobertura temporal	Features disponibles antes de la observación y con latencia documentada.
Denominador	Tasa por tenure/cohorte calculada; no solo volumen de alertas.
Labels	Suficientes positivos en 1m/3m/6m/12m y estabilidad por año.
Leakage	Lista de features revisada; ningún campo futuro o derivado de la alerta.
Balance	Controles similares en tenure, cohorte y otras variables estructurales.
Validación	Split temporal con periodo holdout posterior.

Gate	Criterio para avanzar
Gobernanza	Features permitidas, uso preventivo documentado y revisión de proxies.

9. Estructura sugerida para la página de Confluence

Este documento ya está organizado para copiarse casi 1:1 a Confluence. La página puede mantener la siguiente jerarquía:

- Resumen ejecutivo
- Objetivo y alcance
- Fuentes y escala
- Metodología
- Resultados clave
- Interpretación / limitaciones
- Hoja de ruta del índice
- SQL de referencia
- Criterios de decisión
- Apéndice de métricas

Recomendación de publicación

En Confluence, marcar el reporte como “Working / Exploratory”. Mantener los hallazgos de censura izquierda y efecto de cohorte visibles en la sección de Limitaciones para evitar que el pico de 17-19 años se reutilice fuera de contexto.

Apéndice A. Métricas principales consolidadas

Métrica	Valor	Métrica	Valor
security_alert rows	324,268,295	Parties approx. security_alert	31,916,677
Unique alert creation events	42,318,245	Parties with alert	29,766,492
Events within 7 years	10,951,174	Events after 7 years	1,600,579
2022-2025 first-alert cohort	6,663,521	1% sample	66,643
person_restricted rows	59,554,936,100	Left-censored exact boundary	29,086
Valid non-censored sample	37,492	Corrected tenure median	195 months / 16.3 years

Fin del informe