

Para backups, **no respaldaría todas las tablas que generamos durante la exploración**. Hay varias que fueron QA, versiones anteriores o tablas que pueden reconstruirse fácilmente. Me concentraría en las que permiten reconstruir el proyecto desde la cohorte hasta el modelo.

Yo separaría los backups en tres niveles de prioridad.

Prioridad	Tabla	Por qué conservarla
CRÍTICA	<code>bu_frd.party_first_valid_alert_all</code>	Define el outcome base: primera alerta válida observada por party
CRÍTICA	<code>bu_frd.model_cohort_behavioral_final_3m_2022_2025</code>	Cohorte congelada definitiva: CASE/CONTROL, observation date, split y label
CRÍTICA	<code>bu_frd.model_trades_behavioral_final_13m_2022_2025</code>	Extracción point-in-time de los 13 meses para la cohorte final; costosa de reconstruir
CRÍTICA	<code>bu_frd.model_features_ab_final_2022_2025</code>	Dataset model-ready definitivo para Model A/B
ALTA	<code>bu_frd.model_trades_transition_13m_2022_2025</code>	Contiene las transiciones MOP ya construidas
ALTA	<code>bu_frd.model_party_behavior_monthly_2022_2025</code>	Party-month analítico de los 12 meses
ALTA	<code>bu_frd.model_party_utilization_monthly_2022_2025</code>	Avg + weighted utilization corregida
ALTA	<code>bu_frd.model_party_behavior_windows_2022_2025</code>	Prior 9m / Recent 3m + SD + coverage
MEDIA	<code>bu_frd.model_behavior_features_current_2022_2025</code>	Features de la fórmula Current
MEDIA	<code>bu_frd.model_behavior_features_z_2022_2025</code>	Infraestructura y features Z raw

MEDIA	<code>bu_frd.model_behavior_features_selecte d_2022_2025</code>	Z-score winsorizado/model-ready
MEDIA	<code>bu_frd.model_behavior_features_transfo rmed_2022_2025</code>	Incluye <code>abs_active_accounts _change</code> y <code>log1p_abs_balance_c hange</code>
MEDIA	<code>bu_frd.model_cohort_month_keys_3m_2022 _2025_v2</code>	Mapea los 13 meses: SEED + PRIOR + RECENT
BAJA	<code>bu_frd.model_trade_coverage_13m_2022_2 025_v2</code>	Útil para auditoría de complete-13, pero reconstruible

Si solo pudiera respaldar 4 tablas

Estas serían las indispensables:

1. `bu_frd.party_first_valid_alert_all`
2. `bu_frd.model_cohort_behavioral_final_3m_2022_2025`
3. `bu_frd.model_trades_behavioral_final_13m_2022_2025`
4. `bu_frd.model_features_ab_final_2022_2025`

Con esas cuatro protegemos cuatro capas diferentes:

OUTCOME

`party_first_valid_alert_all`



COHORT / LABEL / SPLIT

`model_cohort_behavioral_final...`



POINT-IN-TIME RAW BEHAVIOR

`model_trades_behavioral_final_13m...`



FINAL MODEL DATASET

`model_features_ab_final...`

La más importante desde el punto de vista de costo de reconstrucción probablemente sea:

`bu_frd.model_trades_behavioral_final_13m_2022_2025`

porque contiene los **98,051,779** registros de trades ya filtrados a nuestra población congelada y a las fechas exactas necesarias. Si desaparece y **trades** cambia, se purga o cambia históricamente, reconstruir exactamente el mismo dataset puede ser difícil.

Para reproducibilidad técnica yo respaldaría 8

Si tienes espacio razonable, mi conjunto recomendado sería:


- 01 bu_frd.party_first_valid_alert_all
- 02 bu_frd.model_cohort_behavioral_final_3m_2022_2025
- 03 bu_frd.model_cohort_month_keys_3m_2022_2025_v2
- 04 bu_frd.model_trades_behavioral_final_13m_2022_2025
- 05 bu_frd.model_trades_transition_13m_2022_2025
- 06 bu_frd.model_party_behavior_monthly_2022_2025
- 07 bu_frd.model_party_behavior_windows_2022_2025
- 08 bu_frd.model_features_ab_final_2022_2025

Y añadiría también:

bu_frd.model_party_utilization_monthly_2022_2025

si queremos preservar explícitamente la corrección de **weighted_utilization**.

Esto permitiría reconstruir prácticamente toda la metodología:



final model-ready features

Las tablas de features intermedias son menos críticas

Por ejemplo:

model_behavior_features_current_2022_2025
model_behavior_features_z_2022_2025
model_behavior_features_selected_2022_2025
model_behavior_features_transformed_2022_2025

son valiosas para auditoría, pero **pueden regenerarse** a partir de:

model_party_behavior_windows_2022_2025

más las fórmulas que ya documentamos.

Por eso, si el backup tiene costo de almacenamiento, priorizaría los datos upstream y la tabla final.

Hay algo más que considero obligatorio respaldar además de tablas

No basta únicamente con las tablas.

Para que el backup sea realmente reproducible, conservaría también el código SQL/R que generó:

cohort
13-month keys
trades extraction
MOP transitions
party-month
Recent3 / Prior9
Current features
Z-score
winsorization thresholds
Model A/B dataset
R model training

Y un pequeño archivo/configuración con los parámetros congelados:

ALERT TYPES
2, 3

LABEL HORIZON
3 calendar months

FEATURE HISTORY
13 months total

SEED
1 month

PRIOR
9 months

RECENT
3 months

CASE:CONTROL
1:10

TRAIN
2022–2023

VALIDATION
2024

TEST
2025

AVG UTIL Z CAP INPUT
1.821143

WEIGHTED UTIL Z CAP INPUT
1.76

ACTIVE Z WINSORIZATION
[-13.27906, 15.01716]

AVG UTIL Z WINSORIZATION
[-29.78358, 33.76045]

WEIGHTED UTIL Z WINSORIZATION
[-37.89802, 40.84790]

Eso evita una situación muy común: tener las tablas pero no recordar **qué versión de una fórmula produjo la tabla**.

Mi recomendación para “Requerimientos especiales — Punto 1”

Si esto es algo que tienes que entregar formalmente, yo declararía como **backup set esencial** estas tablas:

bu_frd.party_first_valid_alert_all
bu_frd.model_cohort_behavioral_final_3m_2022_2025
bu_frd.model_cohort_month_keys_3m_2022_2025_v2
bu_frd.model_trades_behavioral_final_13m_2022_2025
bu_frd.model_trades_transition_13m_2022_2025
bu_frd.model_party_behavior_monthly_2022_2025
bu_frd.model_party_utilization_monthly_2022_2025
bu_frd.model_party_behavior_windows_2022_2025
bu_frd.model_features_ab_final_2022_2025

Es un buen equilibrio entre **reproducibilidad, auditoría y costo**. Las demás tablas derivadas de features pueden reconstruirse a partir de estas.